

**Минобрнауки России**  
**Юго-Западный государственный университет**

Кафедра программной инженерии

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**  
**ПО ПРОГРАММЕ БАКАЛАВРИАТА**

**09.03.04 Программная инженерия**

(код, наименование ОПОП ВО: направление подготовки, направленность (профиль))

**«Разработка программно-информационных систем»**

**Интеллектуальная система мониторинга и распознавания**

**загрязнений водоемов**

(название темы)

**Дипломный проект**

(вид ВКР: дипломная работа или дипломный проект)

**Автор ВКР**

**А. В. Конев**

(подпись, дата)

(инициалы, фамилия)

Группа ПО-116

**Руководитель ВКР**

**Р. А. Томакова**

(подпись, дата)

(инициалы, фамилия)

**Нормоконтроль**

**А. А. Чаплыгин**

(подпись, дата)

(инициалы, фамилия)

**ВКР допущена к защите:**

**Заведующий кафедрой**

**А. В. Малышев**

(подпись, дата)

(инициалы, фамилия)

Курск 2025 г.

**Минобрнауки России**  
**Юго-Западный государственный университет**

Кафедра программной инженерии

УТВЕРЖДАЮ:

Заведующий кафедрой

---

(подпись, инициалы, фамилия)

«\_\_\_\_\_» 20\_\_\_\_ г.

**ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ  
РАБОТУ ПО ПРОГРАММЕ БАКАЛАВРИАТА**

Студента Конева А. В., шифр 21-06-0146, группа ПО-11б

1. Тема «Интеллектуальная система мониторинга и распознавания загрязнений водоемов» утверждена приказом ректора ЮЗГУ от «04» апреля 2025 г. № 1696-с.

2. Срок предоставления работы к защите «9» июня 2025 г.

3. Исходные данные для создания программной системы:

3.1. Перечень решаемых задач:

- 1) проанализировать предметную область;
- 2) разработать архитектуру нейронной сети;
- 3) сформировать датасет и обучить нейронную сеть;
- 4) спроектировать настольное приложение для взаимодействия с системой;
- 5) сконструировать и протестировать настольное приложение.

3.2. Входные данные и требуемые результаты для программы:

- 1) Входными данными для программной системы являются: датасет из изображений, изображения для анализа, файл весов нейронной сети.
- 2) Выходными данными для программной системы являются: проанализированное изображение, файлы весов нейронной сети после обучения.

4. Содержание работы (по разделам):

4.1. Введение.

4.1. Анализ предметной области.

4.2. Техническое задание: основание для разработки, назначение разработки, требования к программной системе, требования к данным программной системы, требования к оформлению документации.

4.3. Технический проект: общие сведения о программной системе, описание используемых библиотек, проектирование архитектуры программной системы, проектирование пользовательского интерфейса программной системы.

4.4. Рабочий проект: спецификация компонентов и классов программной системы, тестирование программной системы, сборка компонентов программной системы.

4.5. Заключение.

4.6. Список использованных источников.

5. Перечень графического материала:

Лист 1. Сведения о ВКРБ.

Лист 2. Актуальность проблемы.

Лист 3. Цель и задачи работы.

Лист 4. Диаграмма прецедентов.

Лист 5. Архитектура интеллектуальной системы.

Лист 6. Архитектура нейронной сети.

Лист 7. Обучение нейронной сети.

Лист 8. Окно анализа изображения.

Лист 9. Окно обучения нейронной сети.

Лист 10. Окно тестирования нейронной сети.

Лист 11. Тестирование обученной нейронной сети.

Лист 12. Тестирование обученной нейронной сети.

Лист 13. Заключение.

Руководитель ВКР

---

(подпись, дата)

P. A. Томакова

(инициалы, фамилия)

Задание принял к исполнению

---

(подпись, дата)

A. B. Конев

(инициалы, фамилия)

## РЕФЕРАТ

Объем работы равен 106 страницам. Работа содержит 28 иллюстраций, 22 таблицы, 20 библиографических источников и 13 листов графического материала. Количество приложений – 2. Графический материал представлен в приложении А. Фрагменты исходного кода представлены в приложении Б.

Перечень ключевых слов: разливы нефти, нейронные сети, мониторинг, спутниковые снимки, распознавание объектов, информационная система, экология, загрязнение водоемов, компьютерное зрение, U-Net, интеллектуальная система, машинное обучение, обработка изображений, предобработка данных, пользовательский интерфейс.

Объектом разработки является система мониторинга водоемов для выявления загрязнений на основе анализа изображений поверхности воды.

Целью выпускной квалификационной работы является разработка интеллектуальной системы для распознавания характерных пятен нефтяных разливов на поверхности водоемов.

В процессе создания системы была разработана архитектура нейронной сети, приложение с графическим интерфейсом для взаимодействия пользователей с системой, сформирован датасет, обучена и протестирована разработанная нейронная сеть.

## ABSTRACT

The volume of work is 106 pages. The work contains 28 illustrations, 22 tables, 20 bibliographic sources and 13 sheets of graphic material. The number of applications is 2. The graphic material is presented in annex A. The layout of the site, including the connection of components, is presented in annex B.

List of keywords: oil spills, neural networks, monitoring, satellite imagery, object recognition, information system, ecology, water pollution, computer vision, U-Net, intelligent system, machine learning, image processing, data preprocessing, user interface.

The object of the research is the waterbody monitoring system for detecting pollution based on water surface imagery analysis.

The goal of this work is to develop an intelligent system for detecting characteristic oil spill patches on the surface of waterbodies.

During the development process, a neural network architecture was designed, a graphical user interface desktop application was developed for user interaction with the system, a dataset was prepared and the developed neural network architecture was trained and tested.

## СОДЕРЖАНИЕ

<b>ВВЕДЕНИЕ</b>	<b>11</b>
1 Анализ предметной области	13
1.1 Нефтяные разливы	13
1.1.1 Экологическая опасность нефтяных разливов	13
1.1.2 Причины и источники загрязнений	15
1.2 Методы мониторинга разливов нефти	17
1.3 Нейронные сети	19
1.3.1 История появления нейронных сетей	19
1.3.2 Современные типы нейронных сетей	23
1.3.3 Сверточные нейронные сети	24
2 Техническое задание	28
2.1 Основание для разработки	28
2.2 Цель и назначение разработки	28
2.3 Требования пользователя к программной системе	28
2.3.1 Требования к данным программной системы	28
2.3.2 Функциональные требования к программной системе	29
2.3.2.1 Сценарий использования «Обучение нейронной сети»	30
2.3.2.2 Сценарий использования «Тестирование нейронной сети»	31
2.3.2.3 Сценарий использования «Анализ изображения»	32
2.3.2.4 Сценарий использования «Сохранение результата анализа»	33
2.3.3 Требования пользователя к интерфейсу приложения	34
2.4 Нефункциональные требования к программной системе	34
2.4.1 Требования к надежности	34
2.4.2 Требования к аппаратному обеспечению	35
2.4.3 Требования к программному обеспечению	35
2.5 Требования к оформлению документации	35
3 Технический проект	37
3.1 Общая характеристика организации решения задачи	37
3.2 Обоснование выбора технологии проектирования	37

3.2.1 Язык программирования Python	37
3.2.2 Описание библиотеки PyTorch	38
3.2.3 Описание библиотек OpenCV и Pillow	38
3.2.4 Описание фреймворка PyQt5	39
3.2.5 Описание библиотеки NumPy	39
3.3 Архитектура программной системы	40
3.4 Описание нейронной сети	41
3.4.1 Метод распознавания пятен нефти	41
3.4.2 Архитектура U-Net	42
3.4.3 Структура нейронной сети	43
3.4.4 Обучение нейронной сети	44
3.5 Проектирование пользовательского интерфейса	45
4 Рабочий проект	49
4.1 Спецификация компонентов и классов программы	49
4.1.1 Модуль main.py	49
4.1.2 Модуль model.py	51
4.1.3 Модуль test.py	52
4.1.4 Модуль train.py	53
4.1.5 Модуль detect.py	57
4.1.6 Модуль analyze_ui.py	58
4.1.7 Модуль train_ui.py	60
4.1.8 Модуль test_ui.py	65
4.2 Модульное тестирование разработанной программной системы	70
4.3 Системное тестирование разработанной программной системы	72
4.4 Сборка программной системы	81
ЗАКЛЮЧЕНИЕ	82
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	83
ПРИЛОЖЕНИЕ А Представление графического материала	87
ПРИЛОЖЕНИЕ Б Фрагменты исходного кода программы На отдельных листах (CD-RW в прикрепленном конверте)	101
	106

Сведения о ВКРБ (Графический материал / Сведения о ВКРБ.png)	Лист 1
Актуальность проблемы (Графический материал / Актуальность проблемы.png)	Лист 2
Цель и задачи работы (Графический материал / Цель и задачи работы.png)	Лист 3
Диаграмма прецедентов (Графический материал / Диаграмма прецедентов.png)	Лист 4
Архитектура интеллектуальной системы (Графический материал / Архитектура интеллектуальной системы.png)	Лист 5
Архитектура нейронной сети (Графический материал / Архитектура нейронной сети.png)	Лист 6
Обучение нейронной сети (Графический материал / Обучение нейронной сети.png)	Лист 7
Окно анализа изображения (Графический материал / Окно анализа изображения.png)	Лист 8
Окно обучения нейронной сети (Графический материал / Окно обучения нейронной сети.png)	Лист 9
Окно тестирования нейронной сети (Графический материал / Окно тестирования нейронной сети.png)	Лист 10
Тестирование обученной нейронной сети (Графический материал / Тестирование обученной нейронной сети.png)	Лист 11
Тестирование обученной нейронной сети (Графический материал / Тестирование обученной нейронной сети.png)	Лист 12
Заключение (Графический материал / Заключение.png)	Лист 13

## ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

ИС – интеллектуальная система.

ИТ – информационные технологии.

ПО – программное обеспечение.

РП – рабочий проект.

ТЗ – техническое задание.

ТП – технический проект.

НС – нейронная сеть.

СНС – сверточная нейронная сеть.

U-Net – архитектура нейронной сети для сегментации изображений.

CUDA – технология параллельных вычислений NVIDIA.

UML (Unified Modelling Language) – язык графического описания для объектного моделирования в области разработки программного обеспечения.

## ВВЕДЕНИЕ

Вода является одним из важнейших природных ресурсов, как для поддержания жизнедеятельности биологических систем, так и для обеспечения разнообразных промышленно-технологических процессов. В настоящее время водные ресурсы активно используются в различных ключевых отраслях промышленности и жизнедеятельности человека. В металлургии вода применяется в процессах флотации – обогащения руд полиметаллов, а также для охлаждения доменных печей. Химическая промышленность активно использует воду для очищения и охлаждения оборудования на различных нефтеперерабатывающих производствах, как компонент для создания продуктов нефтехимической отрасли, таких как пластмассы, реагенты и растворители, удобрения. Вода также активно применяется как один из материалов для создания фармацевтической продукции, такой как инъекционные растворы, препараты для наружного применения(спреи и капли). Энергетический сектор также использует воду для охлаждения энергетического оборудования на атомных и теплоэлектростанциях. Кроме того, вода так же обеспечивает работу гидроэлектростанций.

Загрязнение водоемов негативно сказывается на экологии, здоровье населения, препятствует развитию экономики, поэтому обеспечение экологической безопасности водоемов является одной из наиболее важных задач экологии. В настоящее время особую актуальность приобретает проблема нефтяных разливов.

По этим и другим причинам в настоящее время остро стоит вопрос сохранения чистоты водоемов. Одним из способов достижения этой цели является распознавание загрязнений на поверхности воды.

*Цель настоящей работы – разработка интеллектуальной системы для распознавания характерных пятен нефтяных разливов на поверхности водоемов. Для достижения поставленной цели необходимо решить следующие задачи:*

- провести анализ предметной области;

- сформировать датасет обучающих изображений поверхности воды;
- разработать архитектуру нейронной сети;
- обучить нейронную сеть;
- провести оценку достоверности полученных результатов;
- спроектировать настольное приложение для анализа изображений;
- реализовать приложение, используя графический интерфейс.

*Структура и объем работы.* Отчет состоит из введения, 4 разделов основной части, заключения, списка использованных источников, 2 приложений. Текст выпускной квалификационной работы изложен на 106 страницах.

*Во введении* сформулирована цель работы, поставлены задачи разработки, описана структура работы, приведено краткое содержание каждого из разделов.

*В первом разделе* на стадии анализа предметной области рассматриваются экологические аспекты загрязнения водоемов, причины и последствия разливов нефти, а также методы их распознавания.

*В втором разделе* на стадии технического задания приводятся требования к разрабатываемой интеллектуальной системе.

*В третьем разделе* на стадии технического проектирования представлены проектные решения для системы.

*В четвертом разделе* приводится список классов и их методов, использованных при разработке системы, производится тестирование разработанного настольного приложения.

В заключении излагаются основные результаты работы, полученные в ходе разработки.

В приложении А представлен графический материал. В приложении Б представлены фрагменты исходного кода.

# **1 Анализ предметной области**

## **1.1 Нефтяные разливы**

### **1.1.1 Экологическая опасность нефтяных разливов**

Разлив нефти – аварийный выброс нефти или нефтепродуктов в окружающую среду. Нефтяные разливы происходят с высокой частотой и являются серьезной проблемой нефтегазовой отрасли. Каждый разлив приводит к масштабным последствиям для окружающей среды и требует значительных финансовых затрат для устранения самого разлива и минимизации экологического ущерба.

Ярким примером является инцидент на буровой платформе Deepwater Horizon, принадлежавшей британской нефтегазовой компании British Petroleum. 20 апреля 2010 года, в результате нарушения технологических норм цементирования скважины, произошел взрыв, который привел к гибели 11 человек и неконтролируемому выбросу нефти в Мексиканский залив на протяжении нескольких месяцев. В окружающую среду попало около 400 тысяч тонн нефти. Эта катастрофа, ставшая крупнейшим в истории США разливом нефти, привела к массовой гибели животных, таких как дельфины, морские черепахи, тем самым нанеся колоссальный ущерб морским экосистемам, по некоторым оценкам сохраняющийся и по сей день. Расходы на ликвидацию происшествия, а также затраты на штрафы и компенсации, составили около 65 миллиардов долларов.

16 марта 1978 года французский супертанкер Amoco Cadiz, попав в шторм, потерял управление и разбился о скалы у берегов французского региона Бретань. Это происшествие привело к выбросу 220 тысяч тонн сырой нефти в Атлантический океан, загрязнив более 300 километров французского побережья. Пролившаяся нефть образовала пятно протяженностью 19 километров и поникла в песок на глубину до 50 сантиметров, образовав асфальтоподобные корки, сохранившиеся на протяжении нескольких лет. В защищенных от волн районах нефть сохранялась до 10 лет, тем самым замедляя

восстановление экосистемы, понесшей масштабный ущерб – загрязнение вызвало гибель около 20 тысяч птиц, множества донных организмов, таких как моллюски и ракообразные. Рыбаки сообщали о сокращении уловов в два раза, а сама рыба нередко имела различные язвы и опухоли. Компания Amoco, владелец танкера, выплатила Франции компенсацию в размере 230 миллионов долларов.

Не менее разрушительными оказались последствия крушения танкера Prestige, затонувшего в ноябре 2002 года. Получив повреждения у побережья Испании, корпус судна раскололся, что привело к попаданию примерно 60 тысяч тонн нефти в Атлантический океан. Растигнувшееся на более чем 2000 километров вдоль побережья Галисии нефтяное пятно поставило под угрозу существование 25 охраняемых видов животных, уничтожило популяции рыб, кораллов, моллюсков. Согласно государственной оценке, зачистка побережья Галисии обошлась в 2,5 миллиарда евро, а нанесенный ущерб составил 368 миллионов евро.

В июле 2010 года нефтепровод, принадлежащий американской корпорации Enbridge, разорвало в результате коррозии трубы, что послужило причиной попадания более 2,7 тонн битумной нефти в реку Каламазу, пролившейся на 40 километров по руслу реки и осевшей на дне. Осевшая нефть отравила донные отложения реки, что привело к массовой гибели рыб, популяции которых начали возвращаться только спустя 10 лет. Кроме того, токсины сделали речную воду непригодной для питья, а из-за ядовитых испарений нефти некоторые жители близлежащих районов жаловались на головные боли и тошноту. Поскольку убирать пролившуюся нефть пришлось не только с поверхности, но и со дна реки, очистные мероприятия были значительно затруднены, что повысило стоимость их проведения – она составила примерно 1,2 миллиарда долларов.

Утром 15 декабря 2024 года в Керченском проливе в результате шторма танкеры «Волгонефть-212» и «Волгонефть-239», перевозившие в общей сложности около 9000 тонн мазута, потерпели крушение. По различным оценкам в море попало от 2,5 до 5 тысяч тонн мазута, разлившегося по пло-

щади более 400 м<sup>2</sup>. Загрязнение затронуло около 70 километров береговой линии и привело к гибели более 200 птиц и 70 дельфинов, среди которых были охраняемые виды. Реагируя на происшествие, власти вели режим чрезвычайной ситуации на федеральном уровне и объявили о начале масштабных очистных работ с участием 300 человек и 60 единиц специальной техники, продолжающихся по сей день.

Вследствие принятия множества международных законов и соглашений, совершенствования технологических процессов можно отметить уменьшение частоты крупных происшествий, приводящих к масштабным разливам нефти. Однако, некоторые исследования[1] отмечают, что информация о разливах нефти не всегда достоверна, утверждая, что многие менее крупные инциденты никогда не попадают в поле зрения государственных служб контроля и СМИ, что приводит к отсутствию данных об этих инцидентах в международных и государственных базах.

### 1.1.2 Причины и источники загрязнений

Основными источниками разливов нефти являются различные утечки на этапах добычи, хранения и транспортировки нефти и нефтепродуктов. Причинами возникновения утечек могут являться как стихийные бедствия, такие как штормы, землетрясения и эрозия, так и техногенные факторы, включая отказы оборудования, человеческие ошибки. В таблице 1.1 указаны основные источники попадания нефти в мировой океан[2].

Таблица 1.1 – Основные источники попадания нефти в мировой океан

Источник	млн. т/год
Морская транспортировка (кроме аварийных разливов)	1,83
Аварийные разливы	0,3
Речной сток, включая сточные воды городов	1,9
Сточные воды прибрежной зоны	0,8

## Продолжение таблицы 1.1

Источник	млн. т/год
Естественные нефтяные скважины	0,6
Добыча нефти в море	0,08
<b>Всего</b>	<b>5,51</b>

Наиболее часто разливы нефти появляются в результате аварии на танкере, перевозящем нефть или нефтепродукты. Среди причин возникновения таких аварий можно выделить столкновения, посадки на мель, штормовые повреждения, нарушение герметичности резервуаров. Эти происшествия нередко приводят к масштабным выбросам нефти в морскую или речную среду, при этом загрязняя не только воду, но и зачастую прибрежные зоны, в районе которых произошла авария.

Морская добыча нефти проводится с помощью масштабных комплексов, использующих комплекс инженерно-технических решений. Такие процессы, как повреждения герметизации скважин, отказ оборудования, ошибки при цементировании или нарушения технологических регламентов приводят к выбросам добываемой нефти из подземных резервуаров, что в свою очередь приводит к разливам, плохо поддающимся локализации.

Трубопроводы, используемые для транспортировки нефти на большие расстояния, могут дать течь вследствие коррозии труб, механических повреждений, ошибок в обслуживании. В результате в воде может образоваться нефтяной разлив, который может долго оставаться незамеченным, если трубопровод проходит под водой. Кроме того, серьезную угрозу загрязнения представляет преднамеренное разрушение нефтяной инфраструктуры, особенно в зонах активных боевых действий. Атаки на эти объекты не только приводят к масштабным утечкам, но и затрудняют обнаружение и ликвидацию последствий разливов.

Промышленные предприятия, связанные с переработкой нефти, могут сбрасывать загрязненные нефтью или продуктами ее переработки воды в

близлежащие водоемы. Наряду с этим отходы ремонтных мастерских, автозаправочных станций также могут попадать в водоемы, что приводит к еще большему загрязнению.

Нефтяные утечки происходят не только по вине человека, но и в ходе естественного просачивания из нефтеносных пластов земли через трещины в коре. Чаще всего это происходит в районах активной геологической активности. Несмотря на относительно незначительные объемы, эти утечки также оказывают негативное влияние на экосистемы.

## 1.2 Методы мониторинга разливов нефти

Своевременное обнаружение и ликвидация нефтяных разливов – ключевые задачи для сохранения экологической безопасности водоемов. В связи с этим широко распространены различные виды мониторинга состояния водоемов, среди которых выделяются визуальные методы наблюдения за поверхностью воды. В отличие от лабораторных исследований, визуальное исследование позволяет намного быстрее охватить большие территории и не требует физического контакта с объектом, что позволяет оперативно обнаружить новые разливы нефти, особенно в труднодоступных акваториях.

Одним из самых распространенных методов визуального мониторинга является спутниковая съемка. Современные спутники, оснащенные высокоточными сенсорами, позволяют получить качественные снимки поверхности воды и хорошо отображают аномалии, такие как нефтяные пятна. Спутниковая съемка охватывает сотни квадратных километров поверхности Земли в одном снимке, а использование групп спутников позволяет получать новые данные с высокой периодичностью. Кроме того, использование многих спутников бесплатно, а данные размещены в открытом доступе, что снижает стоимость процедур мониторинга. Однако, зависимость космической съемки от погодных условий и времени суток значительно усложняет наблюдение за поверхностью водоемов и является существенным недостатком этого метода.

В условиях плохой видимости, ограничивающих работу спутников, применяются радиолокационные спутниковые снимки. В отличие от оптиче-

ских сенсоров, радары полагаются на электромагнитные сигналы и фиксирую отраженный поверхностью воды отклик, что и позволяет вести съемку в любую погоду и время суток. На радарных снимках нефтяные пятна обычно проявляются в качестве темных областей, что повышает их информативность в задачах обнаружения нефтяных пятен и пленок. Так, исследование радиолокационных снимков Керченского пролива с использованием спутников Sentinel-1A/B за период с 2017 по 2021 годы показало высокую точность этого метода и позволило исследовать частоту появления, масштаб нефтяных разливов и их источники на основании 2597 пятен, появившихся на снимках за этот период[3]. Несмотря на гибкость этого метода, полученные снимки нередко проявляют сторонние объекты, например различные биологические образования, создавая визуально похожие участки на изображениях. Наличие таких ложных данных требует участия эксперта, отличающего действительные нефтяные пятна от схожих объектов, в процессе мониторинга. Кроме того, радиолокационные изображения значительно дороже, что еще больше повышает стоимость мониторинга.

Наконец, высокую эффективность показал метод аэросъемки поверхности воды. Вместе с развитием беспилотных летательных аппаратов, или БПЛА, наблюдение за водоемами с малой высоты стало высокоэффективным и экономически оправданным методом мониторинга. БПЛА часто оснащаются камерами высокого разрешения, что позволяет получать самые качественные снимки из перечисленных методов, а высокая степень гибкости в построении маршрутов и простота управления делают этот метод самым доступным. Недостатками аэросъемки с помощью БПЛА являются ограниченность радиуса и времени полета, что делает его малоэффективным для мониторинга больших поверхностей воды, таких как моря. Беспилотные аппараты часто используются в составе систем мониторинга вместе с спутниковоыми системами для уточняющих съемок в определенных секторах, снимки которых получены из космоса.

Перечисленные выше дистанционные методы используются для получения визуальных данных, являющихся источником информации для обна-

ружения нефтяных разливов. Чтобы обнаружить загрязнение, необходимо проанализировать полученные данные. Учитывая высокое количество изображений, полученных для анализа, этот процесс занимает значительное время. Более того, если изображения получаются в режиме реального времени, например в формате видеосъемки, то для обнаружения разлива нефти необходимо постоянное присутствие наблюдателя. В настоящее время для задач анализа изображений все чаще используются нейронные сети.

### 1.3 Нейронные сети

#### 1.3.1 История появления нейронных сетей

Идеи, которые легли в основу современных нейронных сетей, берут свое начало в философии и математике, а основные принципы исследовались задолго до появления вычислительных систем как таковых. Правила, руководящие рациональной частью мышления были сформированы Аристотелем в далеких 384 – 322 годах до нашей эры. Впоследствии формальные правила рассуждений и процессы мышления стали предметом исследований не менее известных философов, среди которых были Томас Гоббс (1588-1679), Рене Декарт (1596-1650) и Рудольф Карнап (1891-1970)[4]. Известные математики, такие как Джордж Буль (1815-1864) и Готтлоб Фреге (1848-1925), внесли вклад в разработку логических систем, впоследствии ставших источниками исследований моделирования искусственного интеллекта.

Первая модель искусственного нейрона была предложена Уорреном МакКаллоком и Уолтером Питтсом в 1943 году. Модель представленного ими логического устройства показана на рисунке 1.1.

Модель состоит из входов  $x_1, x_2, \dots, x_n$ , весов  $w_1, w_2, \dots, w_n$ , сумматора и функции активации. Попадая на входы, каждое значение  $x_i$  умножается на значение соответствующего веса  $w_i$ , обозначающего его важность, после чего поступает на сумматор, вычисляющий сумму всех поступивших на него




Рисунок 1.1 – Искусственный нейрон

сигналов:

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Полученная сумма затем сравнивается с пороговым значением  $\theta$ . Если сумма больше, то нейрон возбуждается (выходное значение  $a = 1$ ), в противном случае остается в состоянии покоя (выходное значение  $a = 0$ ). Данная модель может выполнять только бинарные операции, получая на вход значения 0 и 1, требует ручного задания весов, также являющихся бинарными, и порогового значения, что значительно ограничивает её возможности.

Несмотря на ограничения, предложенный МакКаллоком и Питтсем искусственный нейрон показал способность выполнять базовые логические операции, такие как И, ИЛИ и НЕ. Эта модель стала основой для дальнейшей теории нейронных вычислений, а все современные нейронные сети состоят из доработанных версий оригинальных нейронов.

Спустя несколько лет идеи, взяв за основу исследования МакКаллока и Питтса, американский ученый Фрэнк Розенблatt предложил схему перцептрана - устройства, моделирующего восприятие информации головным мозгом человека. Перцептрон состоит из входных датчиков, ассоциативных и реагирующих элементов[5]. Схема простейшего перцептрана показана на рисунке 1.2.




Рисунок 1.2 – Схема однослойного перцептрана

Однослойный перцептрон подходит для решения задачи классификации данных. Для обучения задаются не только входные значения, но и известные ожидаемые результаты. Как и в случае работы нейрона МакКаллока - Питтса, входные значения (S-слой) передаются на ассоциативные элементы (A-слой), где вычисляется взвешенная сумма поступивших сигналов, являющихся произведениями входных значений и весов связей и, наконец, если сумма превышает заданный порог  $\theta$ , то результат подается на реагирующий элемент (R-слой). Если выходное значение не совпадает с ожидаемым, то веса связей S–A модифицируются по формуле:

$$w_{ij}(t + 1) = w_{ij}(t) + \eta \cdot \delta \cdot X_j,$$

где  $t$  и  $t_1$  – номера текущей и следующей итераций процесса,  $\eta$  – коэффициент обучения, находящийся в диапазоне  $0 < \eta < 1$ ,  $\delta$  – разность между ожидаемым и полученным значением,  $i$  и  $j$  – номера входа и нейрона в слое соответственно, после чего перцептрон заново обрабатывает входные значения до тех пор, пока все выходные значения не совпадут с ожидаемыми.

Однако, несмотря на успехи в исследованиях, дальнейшее изучение нейронных сетей столкнулось с скептицизмом. Основной причиной стала невозможность однослойных сетей решать многие простые задачи, среди которых операция «исключающего ИЛИ». Формальное доказательство невозможности решения нелинейных задач однослойным перцептроном было предоставлено Марвином Минским и Сеймуром Папертом в книге «Перцептроны», выпущенной в 1969 году.

После выхода книги, исследовательский интерес к области нейронных систем значительно упал, но не исчез полностью. В 1970-х активно проводились исследования многослойных перцепtronов, был разработан алгоритм обратного распространения ошибки для их обучения, позволяющий преодолеть многие ограничения, обозначенные в работе «Перцептроны», но впоследствии оказавшийся не универсальным. Также разрабатывались альтернативные модели нейронных сетей, такие как когнитрон, предложенная Кунихику Фукусимой в 1975 году, ставшая первой моделью, реализующей обучение без учителя. Основной идеей когнитрона является чередование возбуждающих и подавляющих слоев, что позволяет извлекать отдельные признаки и обобщать изображения. Обучение без учителя основано на конкуренции между нейронами – чем сильнее конкретный вход, тем больший вес ему присваивается, что приводит к заглушению соседних нейронов в конкретном слое. Через пять лет Фукусима представил доработанную и более устойчивую версию когнитрона – неокогнитрон, состоящий из чередующихся слоев S-элементов, отвечающих за выделение признаков, и C-элементов, подавляющих искажения. Когнитрон и неокогнитрон эффективны для решения задач распознавания образов и стал основой для современных сверточных нейронных сетей.

Ключевым моментом развития нейронных сетей явилась разработка метода обратного распространения ошибки. Впервые этот метод был описан в 1974 году Александром Галушкиным и Полом Вербосом, одновременно и независимо сформулировавшим его, и формализован в 1986 году Дэвидом Румельхартом, Джеком Хинтоном и Рональдом Уильямсом. Основной

идеей стало распространение ошибки в обратном прямому распространению сигналов направлении. Метод реализует вычисление градиента ошибки по каждому весу нейрона в сети, начиная с выходного слоя и двигаясь к входному, что позволяет корректировать веса для минимизации ошибки предсказания. Появление обратного распространения предоставляет возможность обучения многослойных нейронных сетей на сложных зависимостях и выполнять более точную классификацию.

### 1.3.2 Современные типы нейронных сетей

В настоящее время нейронные сети являются эффективными инструментами машинного обучения, успешно применяемые в широком спектре задач[6]. На сегодняшний день разработано большое количество различных архитектур нейронных сетей, обладающих уникальными свойствами и наиболее подходящих для реализации конкретных задач.

Многослойный перцептрон, также известный как сеть прямого распространения, является базовой архитектурой полносвязной нейронной сети. Многослойный перцептрон состоит из входного слоя, одного или нескольких скрытых слоев и выходного слоя, причем каждый элемент конкретного слоя связан со всеми элементами следующего за ним слоя.




Рисунок 1.3 – Многослойный перцептрон

Во время обработки информации данные последовательно передаются от входа к выходу без использования сторонних циклов или обратной связи. Обучение полносвязных сетей выполняется при помощи алгоритма обратно-

го распространения ошибки, используемого вместе с параллельным спуском. Эти нейронные сети позволяют аппроксимировать и приближать практически любые непрерывные функции. Недостатками данной модели является плохая масштабируемость на задачи с большими входными данными, а также большие временные затраты на обучение, что делает ее непригодной для работы с изображениями.

Рекуррентная нейронная сеть разработана для работы с последовательными данными, например текстом, аудиосигналами[7]. Отличительной чертой этого типа является наличие внутренней памяти, позволяющей учитывать контекст предыдущих вычислений при обработке новых данных. Базовой архитектурой рекуррентной сети является сеть входных, скрытых и выходных узлов, каждый из которых соединен с остальными. На вход каждого шага вместе с входными данными подается результат обработки предыдущего шага, что позволяет моделировать временные зависимости. В рамках этого подхода следует отметить, что в процессе обработки данных могут возникать проблемы с исчезновением или резким увеличением градиента ошибки. Эти недостатки могут быть устранены в процессе разработки усовершенствованной сети с долгой краткосрочной памятью, LTSM. LTSM является сетью с ячейками памяти, позволяющими сохранять информацию на длительные промежутки времени. Обычно формируется с использованием «вентиляй», использующихся для контроля информации на входах и выходах памяти блоков.

### 1.3.3 Сверточные нейронные сети

Сверточная нейронная сеть (СНС) – особый класс многослойных перцептронов, разработанный с целью распознавания образов[8]. Существенным моментом, определяющим практическую эффективность, является то, что СНС обладают высокой степенью инвариантности к пространственнымискажениям, таким как смещения и повороты. На рисунке 1.5 приведена типовая архитектура СНС.




Рисунок 1.4 – Рекуррентная нейронная сеть




Рисунок 1.5 – Архитектура сверточной нейронной сети

Сверточные нейронные сети работают с изображениями, представленными в виде тензоров – трехмерных массивов чисел или массивов матриц чисел. Для моделирования и отображения подобной информации следует учитывать формат представления изображений в компьютерах – наборы пикселей, содержащих значения интенсивности каждого цветного канала. Данные значения варьируются в диапазоне от 0 до 255, а каналов чаще всего три – красный, зеленый, синий.

СНС состоят из слоев свертки и субдискретизации, полносвязной нейронной сети и выходного слоя. Сверточный слой представляет собой набор карт признаков, имеющих свое ядро свертки – матрицу весовых коэффициентов, устанавливаемых в процессе обучения. Назначением этого слоя является выделение признаков входного изображения и формирования карты признаков, представляющей тензор, в котором каждый канал отвечает за отдельный

признак, такой как границы или текстуры. Для выделения этих признаков используются ядра, также называемые фильтрами – наборы тензоров одинакового размера. Количество тензоров в ядре определяет глубину выходного 3D-массива. Ядра используются в процессе вычисления нового значения выбранного пикселя с учетом значения окружающих его пикселей, называемом сверткой. Фильтр накладывается на левую верхнюю часть изображения, после чего производится покомпонентное умножение значений фильтра и изображения, после чего перемещается по изображению с определенным шагом до тех пор, пока не охватит его полностью[9]. После получения каналов каждого фильтра, результирующие матрицы объединяются в единый тензор.

Входными параметрами сверточного слоя являются:

- тензор размерностью  $W_1 \times H_1 \times D_1$ , где  $W_1$  – высота,  $H_1$  – ширина,  $D_1$  – глубина, или количество каналов;
- $f_c$  – количество фильтров;
- $f_s$  – размер фильтров;
- $S$  – шаг свертки;
- $P$  – количество добавленных пикселей.

На выходе слоя получают тензор размером  $W_2 \times H_2 \times D_2$ , где  $W_2 = (W_1 - f_s + 2P)/S + 1$ ,  $H_2 = (H_1 - f_s + 2P)/S + 1$ ,  $D_2 = f_c$ . Примерами фильтров являются слои подвыборки (пуллинга), сокращающие пространственные размерности изображения в указанное количество раз и слои активации, представляющие из себя функцию, применяющуюся к каждому числу входного изображения.

Размер карт признаков сверточного слоя одинаковый и вычисляется по формуле:

$$(w, h) = (mW - kW + 1, mH - kH + 1)$$

, где  $(w, h)$  – размер сверточной карты,  $mW$ ,  $mH$  – ширина и высота предыдущей карты,  $kW$ ,  $kH$  – ширина и высота ядра.

Подвыборочный слой предназначен для уменьшения размерности карт предыдущего слоя, уплотняя изображения до менее подробных. Производит-

ся подвыборка при помощи операции макспуллинга – выбора максимального значения.




Рисунок 1.6 – Операция макспуллинга

Как правило, каждая карта этого слоя имеет размерность 2x2, что позволяет уменьшить изображение в два раза. Благодаря уменьшению размера увеличивается скорость вычислений, упрощается поиск признаков более высокого уровня на следующих сверточных слоях, так как ненужные детали отбрасываются.

Полносвязный слой является последним в структуре сверточной нейронной сети и представляет собой слой обычного многослойного перцептрона. Его цель – классификация при помощи нелинейной функции, улучшая качество распознавания. Выходной слой связан со всеми нейронами предыдущего слоя, количество нейронов которого обычно соответствует количеству распознаваемых классов.

Сверточные нейронные сети обучаются при помощи алгоритма обратного распространения ошибки. Сначала выполняется прямое распространение от первого слоя к последнему, после чего на выходном слое вычисляется ошибка, передающаяся обратно. На каждом слое вычисляются градиенты обучаемых параметров, используемые для обновления весов при помощи градиентного спуска в конце обратного распространения.

## **2 Техническое задание**

### **2.1 Основание для разработки**

Основанием для разработки является задание на выпускную квалификационную работу бакалавра «Интеллектуальная система мониторинга и распознавания загрязнений водоемов».

### **2.2 Цель и назначение разработки**

Программная система предназначения для автоматического распознавания пятен нефтяных разливов на изображениях и их визуального выделения.

Пользователи должны иметь возможность загружать собственные изображения для анализа системой. Также должен быть реализован функционал сохранения полученных результатов программного анализа .

Задачами данной разработки являются:

- создание интеллектуальной системы распознавания на основе технологий нейронных сетей;
- обучение созданной интеллектуальной системы для распознавания пятен нефтяных разливов;
- разработка функционала для тестирования точности анализа полученной системы;
- реализация настольного приложения с графическим интерфейсом для взаимодействия пользователей с системой.

### **2.3 Требования пользователя к программной системе**

#### **2.3.1 Требования к данным программной системы**

Для обучения нейронной сети и анализа изображений на предмет наличия пятен разливов нефти программной системе требуется датасет, состоящий из изображений в формате JPEG, сохраненные в отдельной папке. Кроме того, для сохранения параметров обученной модели нейронной сети использу-

зуются файлы формата .pth, содержащие веса и смещения модели. Для анализа изображений и тестирования нейронной сети также требуются файлы в формате .pth, содержащие параметры, предварительно полученные после обучения нейронной сети.

### **2.3.2 Функциональные требования к программной системе**

Разработанная программа должна реализовывать следующие функциональные возможности:

- обучение нейронной сети: после выбора директории с изображениями, директории сохранения полученных параметров и параметров обучения, программа запускает обучение нейронной сети и, по его завершении, сохраняет полученный набор параметров в указанную пользователем директорию;
- тестирование нейронной сети: после загрузки тестового изображения и предварительно сохраненного файла параметров нейронной сети, программа должна обрабатывать полученное изображение при помощи модели сети, выводить результат анализа в виде бинарного изображения, идеальный ожидаемый результат, полученный с помощью простого алгоритма обработки и метрики, оценивающие эффективность работы нейронной сети;
- распознавание нефтяных пятен: программа должна распознавать пятна разливов нефти на фотографиях при помощи предоставленных пользователем параметров на загруженном изображении;
- сохранение результатов: пользователь должен иметь возможность сохранения проанализированных изображений на жесткий диск.

На рисунке 2.1 предоставлены функциональные требования к системе, представленные в виде диаграммы прецедентов[10].




Рисунок 2.1 – Диаграмма прецедентов

### 2.3.2.1 Сценарий использования «Обучение нейронной сети»

Заинтересованные лица и их требования: пользователь желает обучить модель нейронной сети для распознавания нефтяных пятен на поверхности водоемов.

Предусловие: программа запущена, выбран режим «Обучение».

Постусловие: программа сохраняет файл, содержащий параметры весов нейронной сети.

Основной успешный сценарий:

1. Пользователь нажимает на кнопку «Выбрать папку» .
2. Программа открывает диалоговое окно выбора папки.
3. Пользователь выбирает папку, содержащую изображения для обучения нейронной сети.

4. Программа отображает путь до выбранной папки в специальном поле.
5. Пользователь нажимает на кнопку «Выбрать путь сохранения».
6. Программа открывает диалоговое окно выбора папки сохранения.
7. Пользователь выбирает директорию, в которой будет сохранен файл, содержащий параметры нейронной сети.
8. Программа отображает путь до выбранной директории сохранения в специальном поле.
9. Пользователь выбирает количество изображений, обрабатываемых нейронной сетью одновременно (размер батча).
10. Пользователь указывает количество эпох обучения.
11. Пользователь нажимает на кнопку «Обучить нейросеть».
12. Программа начинает процесс обучения нейронной сети на полученных изображениях, используя заданные параметры.
13. Программа отображает прогресс процесса обучения пользователю.
14. Программа сохраняет полученный файл, содержащий параметры нейронной сети в папку, указанную пользователем, после завершения процесса обучения.

### **2.3.2.2 Сценарий использования «Тестирование нейронной сети»**

Заинтересованные лица и их требования: пользователь желает протестировать работу предварительно обученную нейронную сеть и узнать качество сегментации.

Предусловие: программа запущена, выбран режим «Тестирование», имеется файл с настройками нейронной сети.

Постусловие: программа отображает метрики качества сегментации, а также сравнение ожидаемых и полученных результатов.

Основной успешный сценарий:

1. Пользователь нажимает на кнопку «Выбрать изображение».
2. Программа открывает диалоговое окно выбора изображения, используемого для тестирования нейронной сети.

3. Пользователь выбирает изображение.
4. Программа отображает путь до выбранного изображения в специальном поле.
5. Пользователь нажимает на кнопку «Выбрать настройки».
6. Программа открывает диалоговое окно выбора файла настроек нейронной сети.
7. Пользователь выбирает файл настроек нейронной сети.
8. Программа отображает путь до выбранного файла настроек в специальном поле.
9. Пользователь нажимает на кнопку «Запустить тестирование».
10. Программа выполняет предварительную обработку изображения.
11. Программа создает ожидаемую маску на основании загруженного изображения при помощи порогового алгоритма.
12. Программа обрабатывает обработанное изображение, используя нейронную сеть с загруженными параметрами.
13. Программа рассчитывает метрики качества сегментации изображения.
14. Программа отображает ожидаемую и полученную нейронной сетью маски классов, а также метрики качества сегментации.

#### **2.3.2.3 Сценарий использования «Анализ изображения»**

Заинтересованные лица и их требования: пользователь желает проанализировать изображение на наличие нефтяного разлива.

Предусловие: программа запущена, выбран режим «Анализ изображения», имеется файл с настройками нейронной сети.

Постусловие: программа отображает результаты анализа изображения.

Основной успешный сценарий:

1. Пользователь нажимает на кнопку «Выбрать изображение».
2. Программа открывает диалоговое окно выбора анализируемого изображения.
3. Пользователь выбирает необходимое изображение.

4. Программа отображает путь до выбранного изображения в специальном поле и выводит его в главное окно.
5. Пользователь нажимает на кнопку «Выбрать модель».
6. Программа открывает диалоговое окно выбора файла с настройками модели.
7. Пользователь выбирает файл настроек нейронной сети.
8. Программа отображает путь до выбранного файла в специальном поле.
9. Пользователь нажимает на кнопку «Анализировать».
10. Программа выполняет предварительную обработку изображения.
11. Программа анализирует обработанное изображение на предмет наличия пятен нефтяных разливов с помощью нейронной сети.
12. Программа отображает результат анализа на исходной версии изображения, загруженной пользователем в главном окне программы.

#### **2.3.2.4 Сценарий использования «Сохранение результата анализа»**

Заинтересованные лица и их требования: пользователь желает сохранить результат анализа изображения нейронной сетью.

Предусловие: программа запущена, выбран режим «Анализ изображения», изображение предварительно загружено и проанализировано.

Постусловие: программа сохраняет результат обработки в виде изображения на жесткий диск.

Основной успешный сценарий:

1. Пользователь нажимает на кнопку «Сохранить результат».
2. Программа открывает диалоговое окно выбора папки для сохранения результата анализа.
3. Пользователь выбирает необходимую папку.
4. Программа сохраняет результат анализа в указанную папку в виде изображения.

5. Программа уведомляет пользователя об успешном сохранении изображения.

### **2.3.3 Требования пользователя к интерфейсу приложения**

Приложение должно иметь следующие экраны:

1. Экран «Анализ изображения». Основной экран, реализующий функционал распознавания пятен нефти на изображениях поверхности водоемов, где реализована возможность загрузки изображения для поиска нефтяных пятен, просмотр результата работы нейронной сети и его сохранения на жесткий диск.

2. Экран «Обучение». Экран, позволяющий обучать нейронную сеть искать пятна разливов нефти на изображениях. Должен содержать возможность выбора папки, содержащей датасет для обучения, и директории сохранения файла, содержащего настройки параметров нейронной сети, полученные во время ее обучения.

3. Экран «Тестирование». Экран для тестирования обученной модели, позволяющий выбрать файл настроек нейронной сети, тестовое изображение, а также отображающий исходное изображение, ожидаемый результат и фактический результат обработки тестового изображения нейронной сетью.

## **2.4 Нефункциональные требования к программной системе**

### **2.4.1 Требования к надежности**

Программная система должна обеспечивать стабильную работу в различных условиях эксплуатации. В процессе работы приложения могут возникнуть следующие аварийные ситуации:

- отсутствие файлов изображений в папке, выбранной как директория хранения датапака;
- попытка загрузить в программу поврежденное изображение;
- ошибки загрузки или сохранения файлов настроек моделей или изображений из-за проблем с файловой системой;

- ошибки в работе программы из-за загрузки пользователем файлов некорректных форматов.

Для предотвращения аварийных ситуаций программа должна корректно обрабатывать исключения при работе с файлами, предоставляя пользователям информативные сообщения об ошибках. В случае проблем с отсутствием прав доступа к директории сохранения файлов, полученных в результате работы программы, программа должна открывать диалоговое окно с выбором другой директории.

#### **2.4.2 Требования к аппаратному обеспечению**

Для корректной работы программного продукта требуется центральный процессор с количеством ядер от 6 и выше с частотой ядра от 2.4 ГГц. Размер необходимой оперативной памяти - 8 Гб и выше. Кроме того, для отрисовки графического интерфейса требуется видеокарта с объемом графической памяти 4 Гб и выше, монитор. Наконец, для управления программой необходимы клавиатура и мышь.

Для ускорения процесса обучения нейронной сети возможно использование вычислительных ресурсов графического адаптера NVIDIA с поддержкой технологии CUDA.

#### **2.4.3 Требования к программному обеспечению**

Для запуска и работы программы требуется компьютер под управлением операционной системы Windows 10 или Windows 11. При использовании графических адаптеров NVIDIA с поддержкой технологии CUDA для ускорения обучения нейронной сети необходима последняя версия драйверов соответствующего адаптера, а также программы CUDA Toolkit и cuDNN.

### **2.5 Требования к оформлению документации**

Требования к стадиям разработки программ и программной документации для вычислительных машин, комплексов и систем независимо от их

назначения и области применения, этапам и содержанию работ устанавливаются ГОСТ 19.102–77. и ГОСТ 34.601-90.

Программная документация должна включать в себя:

- анализ предметной области;
- техническое задания;
- технический проект;
- рабочий проект.

### **3 Технический проект**

#### **3.1 Общая характеристика организации решения задачи**

Необходимо спроектировать и разработать интеллектуальную систему распознавания пятен разливов нефти на поверхности водоемов.

Интеллектуальная система состоит из модели нейронной сети и приложения, отвечающего за взаимодействие пользователей с системой. В приложении необходимо иметь возможность взаимодействовать с нейронной сетью при помощи графического интерфейса пользователя. Под взаимодействием понимается загрузка изображений, содержащих пятна нефтяных разливов, возможность распознавания пятен при помощи модели нейронной сети, а также её обучение и тестирование.

#### **3.2 Обоснование выбора технологии проектирования**

Технологии, языки программирования и архитектурные решения, использованные для создания интеллектуальной системы, отвечают современным практикам разработки и позволяют достичь высокой производительности и отказоустойчивости программы.

##### **3.2.1 Язык программирования Python**

Для реализации программной системы был использован язык Python. Python – язык программирования высокого уровня обладающий высокой степенью гибкости[11] и широко используемый как в научной отрасли, так и для коммерческой разработки. Особенно хорошо Python подходит для построения интеллектуальных систем и анализа изображений благодаря богатой системе внешних библиотек, позволяющих значительно упростить построение модели нейронной сети[12], подготовку данных, работу с изображениями, создание графического интерфейса пользователя. Интуитивный синтаксис языка позволяет снизить количество синтаксических ошибок, что в свою очередь значительно ускоряет разработку программных продуктов. Встроенная поддержка различных парадигм программирования позволяет удобно

реализовывать модульную архитектуру приложения с использованием классов, функций и последовательного кода. Кроссплатформенность языка облегчает адаптацию системы для работы на различных операционных системах, что при желании позволит легко создать нативные версии приложений для таких операционных систем, как Linux и macOS[13].

### 3.2.2 Описание библиотеки PyTorch

Для разработки модели нейронной сети была выбрана библиотека PyTorch. PyTorch является открытой библиотекой, содержащей широкий набор инструментов для машинного обучения. Данная библиотека активно применяется в разнообразных научных исследованиях, использующих модели нейронных сетей. PyTorch зарекомендовала себя благодаря гибкости, лаконичному синтаксису и обширным возможностям построения и обучения нейронных сетей[14].

Для определения структуры вычислений PyTorch использует динамический вычислительный граф, что означает построение графа операций непосредственно в процессе выполнения программы вместо предварительного определения его структуры. Данный подход значительно упрощает модификацию и отладку архитектуры модели нейронной сети, позволяет удобно реализовывать операции обучения, тестирования и анализа при помощи полученной модели нейронной сети.

### 3.2.3 Описание библиотек OpenCV и Pillow

OpenCV и Pillow (PIL) — две широко используемые библиотеки для обработки изображений и компьютерного зрения. OpenCV обеспечивает высокую производительность при работе с изображениями, поддерживая такие операции, как выделение контуров объектов и визуализация результатов. В свою очередь, Pillow предлагает удобный интерфейс для базовой обработки изображений, включая изменение размеров, форматов, наложение масок и простые преобразования. В данной работе OpenCV применяется преимущественно для задач выделения контуров, тогда как Pillow используется для

предварительной обработки и модификации изображений, а также их сохранения.

### **3.2.4 Описание фреймворка PyQt5**

PyQt5 является набором расширений кроссплатформенного графического фреймворка Qt 6 версии для языка Python. PyQt5 позволяет создавать графические интерфейсы пользователя различной сложности – от простых оконных приложений до многооконных систем с развитой логикой взаимодействий.

Одним из ключевых преимуществ PyQt5 является большое число готовых элементов графического интерфейса, таких как кнопки, выпадающие списки, таблицы, позволяющих строить полноценный интуитивный пользовательский интерфейс. Графический интерфейс PyQt можно разрабатывать как вручную в коде, так и при помощи визуального редактора Qt Designer, возвращающего пользователю готовый Python-код для графического интерфейса. Кроссплатформенность PyQt5 позволяет запускать приложения, разработанные для операционной системы Windows на компьютерах с Linux и macOS не требуя значительных изменений, что позволяет без особых усилий создавать мультиплатформенные версии приложений.

### **3.2.5 Описание библиотеки NumPy**

Библиотека NumPy предназначена для работы с многомерными массивами и матрицами, а также позволяет проводить сложные математические вычисления с высокой скоростью. NumPy предлагает большое количество функций для работы с массивами, таких как арифметические и логические операции, линейная алгебра.

NumPy позволяет преобразовывать изображения и их маски в числовые массивы для дальнейшей обработки, а также объединять и нормализовать эти маски. Компактный синтаксис и высокая производительность делают его подходящим для практических любых проектов, связанных с обработкой данных[15].

### 3.3 Архитектура программной системы

На рисунке 3.1 в виде UML-диаграммы[16] представлена архитектура программной системы.




Рисунок 3.1 – Архитектура системы

Интеллектуальная система состоит из следующих компонентов:

1. Основное окно. Основное окно отвечает за вызов главного окна программной системы и инициализацию трех режимов работы программы и переключение между ними.
2. Модуль распознавания. Данный модуль вызывает окно для распознавания изображения, позволяющее выбрать изображение и параметры модели для анализа нейронной сетью, запускает процесс распознавания и отображает результат.
3. Функция распознавания. Использует модель нейронной сети и ее параметры для анализа полученного изображения, возвращая результат работы и сохраняя его в виде файла.

4. Модуль обучения. Вызывает окно, позволяющее выбрать директорию, содержащую изображения для обучения нейронной сети, и указать директорию для сохранения файла параметров обученной нейронной сети. Кроме того, данный модуль запускает процесс, отвечающий за обучение нейронной сети и отображение прогресса завершения обучения.

5. Функция обучения модели. Компонент загружает изображения для обучения, преобразует их в требуемый для обучения нейронной сети вид и обучает модель, сохраняя полученный в результате файл параметров.

6. Модуль тестирования. Вызывает окно, позволяющее выбрать параметры модели, тестовое изображение и запускает процесс, отвечающий за тестирование модели нейронной сети с сохраненными параметрами и возвращает результаты тестирования. Также отображает полученные метрики и результаты.

7. Функция тестирования. Выполняет оценку точности модели нейронной сети с параметрами, загруженными из предварительно сохраненного файла. Сравнивает результат анализа изображения нейронной сетью и ожидаемый результат, полученный при помощи пороговой фильтрации.

8. Модель нейронной сети. Хранит в себе структуру используемой в системе нейронной сети.

### **3.4 Описание нейронной сети**

Для распознавания нефтяных пятен на изображениях поверхностей водоемов была спроектирована и разработана модель сверточной нейронной сети. Сверточные нейронные сети – односторонние модели, разработанные для распознавания образов на изображениях.

#### **3.4.1 Метод распознавания пятен нефти**

Для определения пятен нефти на изображениях сверточные нейронные сети могут применяться в соответствии с одним из следующих подходов:

- распознавание объектов на изображении;
- семантическая сегментация.

Распознавание объектов обучает нейронную сеть распознавать образы, выделяя их при помощи ограничивающих рамок прямоугольной области, окружающих распознанный объект. Нейронная сеть, обученная при помощи семантической сегментации, выполняет пиксельную разметку, присваивая каждому пикселю метку определенного класса. В отличие от распознавания объектов, семантическая сегментация позволяет снизить погрешность распознавания и повысить точность локализации, минимизируя возможность ложного распознавания сторонних объектов, окружающих нефтяные разливы, зачастую представляющие собой пятна неправильной формы.

Для создания интеллектуальной системы был выбран семантический подход сегментации, основанный на распознавании определенных уровней яркости пикселей. В большинстве случаев при переводе изображения, содержащего пятна разлива нефти, в полутона, объект интереса (пятно) будет представлен скоплениями темных пикселей. Обучив нейронную сеть распознавать пиксели, яркость которых ниже определенного порогового значения, можно эффективно обнаруживать и выделять нефтяные разливы на изображении.

### 3.4.2 Архитектура U-Net

В данной работе была реализована нейронная сеть типа U-Net, адаптированная под особенности предметной области.

Архитектура U-Net была представлена в 2015 году группой исследователей из Университета Фрайбурга. Данная архитектура получила широкое распространение благодаря способности выделять объекты различной формы и масштаба с высокой точностью даже на маленьких объемах обучающих выборок. Характерной особенностью U-Net является симметричная структура: левая часть сети, или энкодер, выполняет последовательное сжатие входного изображения, а правая, или декодер – восстановление пространственного разрешения до исходного размера[17].




Рисунок 3.2 – Архитектура сети U-Net

Ключевым элементом U-Net являются прямые соединения между соответствующими уровнями энкодера и декодера, позволяющие использовать признаки, извлеченные на ранних этапах обработки, передавая их на этапы восстановления изображения, что предотвращает потерю пространственной информации. Отмеченные особенности позволяют с легкостью адаптировать U-Net для использования в различных областях, например медицинская диагностика, спутниковый мониторинг, обработка изображений, полученных с беспилотных летательных аппаратов.

### 3.4.3 Структура нейронной сети

Реализация модели U-Net состоит из энкодера, узкого места и декодера. Энкодер состоит из двух уровней, содержащих по два сверточных слоя, преобразующих 1 канал в 64 и 64 канала в 128, создавая 64 и 128 карт признаков соответственно, каждая из которых отвечает за определенные особенности изображения, такие как горизонтальные и вертикальные края, их комбинации, текстуры. Каждый из сверточных слоев, используемых в уровнях, имеет размерность маски 3x3, проходящей по изображению с шагом 1 (маска смещается на 1 пиксель) и извлекающей вышеуказанные признаки с сохранением размеров изображения. После извлечения энкодер уменьшает изоб-

ражение в 2 раза, используя маску размерностью  $2 \times 2$ , смещающуюся на 2 пикселя за шаг. Операция уменьшения повторяется после каждого извлечения признаков, в общем уменьшая размеры изображения в 4 раза.

Блок узкого места продолжает процесс извлечения признаков, распознавая абстрактные признаки, такие как крупные структуры и формы, добавляя дополнительные 128 каналов до общей суммы 256, перемещая маску размерности  $3 \times 3$  шагом в 1. Размер самого изображения при этом остается неизменным.

Слой декодера возвращает изображению исходные размеры. При помощи перемещения маски размерностью  $2 \times 2$  с шагом 2 увеличивает размер полученного из предыдущего этапа изображения в 2 раза, растягивая каждый пиксель в блок размером  $2 \times 2$  и корректируя значения при помощи весов, вместе с этим комбинируя данные признаков, уменьшая размерность каналов в 2 раза до 128. Затем слой уточняет признаки, полученные из предыдущего шага и признаки, полученные энкодером на 2 шаге свертки, и возвращает изображение с размерностью, полученной на предыдущем шаге и 256 картами признаков, содержащую признаки как высокого, так и низкого уровней. Наконец, сверточный блок использует маску  $3 \times 3$  с шагом 1 и уточняет карты признаков высокого уровня из узкого места и низкого уровня из энкодера, тем самым уменьшая количество каналов в два раза, до 128. Данный процесс повторяется два раза, по одному на каждый уровень декодера, восстанавливая исходные размеры изображения и объединяя карты признаков. Финальный слой объединяет оставшиеся 64 карты признаков в единую маску, значения которой обозначают вероятность принадлежности пикселя к классу разлива, которая, после применения порога функцией активации, изменяется в бинарную маску (1, если пиксель является частью разлива и 0, если нет).

#### 3.4.4 Обучение нейронной сети

Обучение модели нейронной сети происходит на наборе полутоновых изображений формата JPEG разрешения 624x320. Целевые маски для обучения создаются на основании яркостных признаков при помощи алгорит-

ма бинаризации с порогом 0,5. Размер целевых масок совпадает с размером входного изображения. Датасет загружается из отдельной директории и полностью используется для обучения без разделения на обучающую, валидационную и тестовую выборки.

Обучение происходит на протяжении 25 эпох на группах из двух изображений. Дополнительные аугментации не применяются. Обучение проводится на центральном процессоре, при этом реализована возможность обучения на графическом процессоре при наличии поддерживающего устройства. На каждой эпохе для каждой группы изображений входные данные и маски отправляются на вычислительное устройство, модель делает предсказание, после чего вычисляется потеря по формуле:

$$L = - [y \cdot \log(p) + (1 - y) \cdot \log(1 - p)],$$

где  $y$  – идеальное значение,  $p$  – предсказанная вероятность. Наконец, градиенты обнуляются, вычисляются заново, после чего веса модели обновляются.

### 3.5 Проектирование пользовательского интерфейса

На основании требований к пользовательскому интерфейсу, представленных в пункте 2.3.3, был разработан графический интерфейс программной системы[18].

На рисунке 3.3 представлен макет интерфейса окна «Анализ изображения». Макет содержит следующие элементы:

1. Кнопка переключения режимов окна.
2. Поле, содержащее путь до анализируемого изображения.
3. Кнопка выбора изображения для анализа.
4. Поле, содержащее путь до выбранного файла параметров нейронной сети.
5. Кнопка выбора файла параметров нейронной сети.
6. Поле для отображения загруженного изображения и результатов анализа.
7. Кнопка для запуска распознавания нефтяных пятен.

8. Кнопка для сохранения результатов анализа нейронной сети.




Рисунок 3.3 – Макет интерфейса окна «Анализ изображения»

На рисунке 3.4 представлен макет интерфейса окна «Обучение». Макет содержит следующие элементы:

1. Кнопка переключения режимов окна.
2. Поле, содержащее путь до выбранной папки с изображениями для обучения нейронной сети.
3. Кнопка выбора папки с изображениями для обучения нейронной сети.
4. Поле, содержащее путь до папки, в которую необходимо сохранить параметры модели.
5. Кнопка для выбора папки, в которую необходимо сохранить параметры модели.
6. Элемент для выбора количества изображений, обрабатываемых одновременно.
7. Поле для выбора количества эпох обучения нейронной сети.
8. Шкала прогресса завершения эпохи обучения нейронной сети.

9. Поле для отображения информации о процессе обучения нейронной сети.

10. Кнопка для запуска обучения.




Рисунок 3.4 – Макет интерфейса окна «Обучение»

На рисунке 3.5 представлен макет интерфейса окна «Тестирование». Макет содержит следующие элементы:

1. Кнопка переключения режимов окна.
2. Поле, содержащее путь до тестового изображения.
3. Кнопка выбора изображения для тестирования нейронной сети.
4. Поле, содержащее путь до выбранного файла параметров нейронной сети.
5. Кнопка выбора файла параметров нейронной сети.
6. Поле вывода метрик тестирования нейронной сети.
7. Поле для отображения исходного изображения.
8. Поле для отображения ожидаемого результата обработки.

9. Поле для отображения фактического результата обработки изображения нейронной сети.

10. Кнопка для запуска тестирования.




Рисунок 3.5 – Макет интерфейса окна «Тестирование»

## 4 Рабочий проект

### 4.1 Спецификация компонентов и классов программы

#### 4.1.1 Модуль main.py

Модуль предоставляет графический интерфейс с меню для переключения между тремя режимами работы: анализ изображений, обучение и тестирование нейронной сети.

Класс – MainWindow.

Описание класса MainWindow. Класс предназначен для управления главным окном приложения и переключения между режимами работы программы. Базовый класс – QMainWindow, стандартный класс библиотеки PyQt5. Интерфейсы: панель меню, позволяющая переключать режимы работы программы; центральный виджет QStackedWidget, отображающий интерфейс активного режима работы. Константы: отсутствуют. Внутренние поля представлены в таблице 4.1.

Таблица 4.1 – Внутренние поля класса MainWindow

Внутреннее поле	Тип	Описание
stack	QStackedWidget	Содержит три вида графического интерфейса для каждого режима работы программы
analysis_widget	ImageAnalysisWidget	Виджет, содержащий графический интерфейс режима анализа изображений

## Продолжение таблицы 4.1

Внутреннее поле	Тип	Описание
training_widget	TrainingWidget	Виджет, содержащий графический интерфейс режима обучения нейронной сети
testing_widget	TestingWidget	Виджет, содержащий графический интерфейс режима тестирования нейронной сети

Методы класса представлены в таблице 4.2.

Таблица 4.2 – Методы класса MainWindow

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	Не имеет	Не имеет	Инициализирует главное окно программы, задает его параметры, заголовок, панель меню с действиями для переключения режимов
switch_mode	index – идентификатор активного режима окна	Не имеет	Переключает графический интерфейс в соответствии с выбранным режимом работы

#### 4.1.2 Модуль model.py

Модуль определяет структуру нейронной сети UNet, используемой для обнаружения разливов нефти.

Класс – UNet.

Описание класса UNet. Класс реализует модель UNet для сегментации и распознавания пятен нефтяных разливов на поверхности водоемов. Базовый класс – nn.Module, стандартный класс библиотеки PyTorch. Интерфейсы: общедоступные методы `__init__` и `forward`. Константы отсутствуют. Внутренние поля представлены в таблице 4.3.

Таблица 4.3 – Внутренние поля класса UNet

Внутреннее поле	Тип	Описание
enc1	nn.Sequential	Первый блок энкодера
enc2	nn.Sequential	Второй блок энкодера
pool	nn.MaxPool2d	Слой максимального пулинга, уменьшающий разрешение
bottleneck	nn.Sequential	Блок узкого места
upconv2	nn.ConvTranspose2d	Второй слой повышения разрешения
dec2	nn.Sequential	Второй блок декодера
upconv1	nn.ConvTranspose2d	Первый слой повышения разрешения
dec1	nn.Sequential	Первый блок декодера
final_conv	nn.Conv2d	Финальный сверточный слой, создающий выходную маску признаков

Методы класса представлены в таблице 4.4.

Таблица 4.4 – Методы класса UNet

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
<code>__init__</code>	<code>in_channels</code> – количество входных каналов; <code>out_channels</code> – количество выходных каналов	Не имеет	Инициализирует архитектуру UNet
<code>forward</code>	<code>x</code> – входной тензор	<code>torch.Tensor</code> – выходная маска признаков	Выполняет прямой проход через нейронную сеть, возвращая итог сегментации
<code>conv_block</code>	<code>in_c</code> – входные каналы; <code>out_c</code> – выходные каналы	<code>nn.Sequential</code> – контейнер сверточного блока	Определяет сверточный блок с двумя сверточными слоями и функциями активации

#### 4.1.3 Модуль `test.py`

Модуль содержит функции для оценки обученной модели UNet на одном изображении. Не содержит классов. Методы модуля:

1. `dice_coefficient`. Вычисляет коэффициент Dice для предсказанной маски. Входные данные:

- `pred` (тип `torch.Tensor`) – предсказанная маска;
- `target` (тип `torch.Tensor`) – целевая маска;
- `smooth` (тип `float`, значение по умолчанию –  $1e^{-6}$ ) – стабилизирующая константа для избежания деления на ноль.

Возвращаемые данные – коэффициент Dice в виде float-числа.

2. `iou_score`. Вычисляет пересечение по объединению (коэффициент IoU) для предсказанной маски. Входные данные:

- `pred` (тип `torch.Tensor`) – предсказанная маска;

- target (тип torch.Tensor) – целевая маска;
- smooth (тип float, значение по умолчанию –  $1e^{-6}$ ) – стабилизирующая константа для избежания деления на ноль.

Возвращаемые данные – коэффициент пересечения по объединению в виде float-числа.

3. `load_image`. Загружает изображение и выполняет предобработку для дальнейшего анализа нейронной сетью. Входные данные:

- path (тип str) – путь к загружаемому изображению;
- size (тип tuple) – целевой размер изображения для дальнейшей обработки нейронной сетью.

Возвращаемые данные: нормализованный массив изображения типа `np.ndarray`.

4. `run_evaluation`. Выполняет оценку точности обученной модели нейронной сети и возвращает результаты обработки и метрики. Входные данные:

- image\_path (тип str) – путь к анализируемому изображению;
- weights (тип str) – путь к оцениваемым весам модели;
- threshold (тип float, значение по умолчанию = 0,3) – порог для бинаризации масок

Возвращаемые данные – значения коэффициентов Dice и IoU, исходное изображение, ожидаемую маску, полученную при помощи пороговой бинаризации и предсказанную сетью маску в виде словаря `dict`.

#### 4.1.4 Модуль `train.py`

Модуль управляет загрузкой датасета и обучением нейронной сети.

Классы: `dataset` и `Trainer`.

Описание класса `dataset`. Класс загружает и предобрабатывает изображения и создает псевдомаски на основании порога для обучения нейронной сети. Базовый класс – `Dataset`, стандартный класс библиотеки PyTorch. Интерфейсы – общедоступные методы `__init__`, `__len__`, `__getitem__`, общедоступные атрибуты `image_dir`, `images`. Константы отсутствуют. Внутренние поля представлены в таблице 4.5.

Таблица 4.5 – Внутренние поля класса dataset

Внутреннее поле	Тип	Описание
image_dir	str	Папка, содержащая датасет
images	list	Список имен файлов изображений для обучения
threshold	float	Порог для создания обучающих масок

Методы класса представлены в таблице 4.6.

Таблица 4.6 – Методы класса dataset

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	image_dir – путь к папке с датасетом; threshold – порог для создания обучающих масок	Не имеет	Инициализирует датасет, проверяя директорию и загружая имена файлов изображений
__len__	Не имеет	Количество изображений в датасете	Определяет количество изображений в датасете
__getitem__	idx – порядковый номер обрабатываемого изображения	тензор изображения и маски	Загружает, предобрабатывает и создает обучающую маску для изображений датасета

Описание класса Trainer. Класс управляет обучением модели нейронной сети и отправляет сигналы о состоянии процесса обучения для обновления

ния графического интерфейса. Базовый класс – `QObject`, стандартный класс библиотеки `PyQt5`. Интерфейсы – сигналы о состоянии процесса обучения, общедоступный метод `__init__`. Константы отсутствуют. Внутренние поля представлены в таблице 4.7.

Таблица 4.7 – Внутренние поля класса Trainer

Внутреннее поле	Тип	Описание
<code>epoch_start_signal</code>	<code>pyqtSignal[int, int]</code>	сигнал начала эпохи, содержащий её номер и общее количество эпох
<code>epoch_complete_signal</code>	<code>pyqtSignal[[int, float, float, float, float]]</code>	сигнал завершения эпохи, содержащий её номер и средние значения потерь при обучении, потерю на тестовой выборке, метрик Dice и IoU
<code>batch_progress_signal</code>	<code>pyqtSignal[int, int, float]</code>	сигнал прогресса обработки батча, содержащий его номер, потерю, общее число батчей
<code>training_complete_signal</code>	<code>pyqtSignal[str]</code>	сигнал завершения обучения
<code>image_dir</code>	<code>str</code>	Путь к папке с датасетом
<code>save_path</code>	<code>str</code>	Путь для сохранения весов модели
<code>batch_size</code>	<code>int</code>	Размер батча для обучения

## Продолжение таблицы 4.7

Внутреннее поле	Тип	Описание
epochs	int	Количество эпох обучения
lr	float	Скорость обучения
threshold	float	Порог для создания обучающих и тестовых масок

Методы класса представлены в таблице 4.8.

Таблица 4.8 – Методы класса Trainer

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	image_dir – путь датасета; save_path – путь сохранения весов; batch_size – размер батча; epochs – количество эпох; lr – скорость обучения; threshold – порог для обучающих масок	Не имеет	Инициализирует процесс обучения с определенными параметрами

#### Продолжение таблицы 4.8

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
run	Не имеет	Не имеет	Обучает нейронную сеть, отправляя сигналы о прогрессе, и сохраняет параметры модели по завершении обучения

В модуле train.py также реализован метод main(), предназначенная для получения аргументов обучения из графического интерфейса и запуска обучения при помощи Trainer. Метод не имеет входных и возвращаемых данных.

#### 4.1.5 Модуль detect.py

Модуль используется для анализа изображений с использованием обученной модели нейронной сети, обнаруживая и выделяя пятна нефтяных разливов. Не содержит классов. Методы модуля:

1. load\_model. Загружает и инициализирует модель нейронной сети с указанными параметрами. Входные данные – model\_path (тип str) – путь к файлу параметров модели. Возвращаемые данные – элемент класса Unet модуля model.py с загруженными из файла весами.

2. analyze\_return. Метод обрабатывает изображение, используя нейронную сеть, создает бинарную маску разлива и возвращает исходное изображение с выделенными распознанными пятнами нефтяных разливов. Входные данные:

- image\_path (тип str) – путь к анализируемому изображению;
- model\_path (тип str) – путь к файлу параметров нейронной сети;
- threshold (тип float, значение по умолчанию – 0,3) – порог для бинаризации маски.

Возвращаемые данные – изображение с выделенными распознанными нефтяными пятнами в формате np.ndarray.

#### 4.1.6 Модуль analyze\_ui.py

Модуль содержит графический интерфейс режима анализа изображений с использованием предварительно обученной модели нейронной сети.

Класс – ImageAnalysisWidget.

Описание класса ImageAnalysisWidget. Класс содержит графический интерфейс, позволяющий выбрать анализируемое изображение, файл параметров нейронной сети, запустить процесс анализа и сохранить результат и отображающий этот результат. Базовый класс – QWidget, стандартный класс библиотеки PyQt5. Интерфейсы – поля для путей к изображению и модели, кнопки для выбора этих путей, начала анализа, сохранения результата, область отображения изображения. Константы отсутствуют. Внутренние поля класса представлены в таблице 4.9.

Таблица 4.9 – Внутренние поля класса ImageAnalysisWidget

Внутреннее поле	Тип	Описание
image_path	str	путь к выбранному изображению
model_path	str	путь к выбранному файлу параметров нейронной сети
result_img	np.ndarray	проанализированное изображение с разметкой
path_label	QLabel	надпись "Изображение для анализа:"
path_field	QTextEdit	текстовое поле для отображения пути к изображению
select_button	QPushButton	кнопка для выбора изображения

## Продолжение таблицы 4.9

Внутреннее поле	Тип	Описание
model_label	QLabel	надпись "Путь к модели нейросети:"
model_path_field	QTextEdit	текстовое поле для отображения пути к модели
select_model_button	QPushButton	кнопка для выбора файла параметров
image_label	QLabel	поле для отображения изображения
analyze_button	QPushButton	кнопка для анализа изображения
save_button	QPushButton	кнопка для сохранения результата анализа

Методы класса представлены в таблице 4.10.

Таблица 4.10 – Методы класса ImageAnalysisWidget

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	Не имеет	Не имеет	Инициализирует графический интерфейс, включая его макет и элементы
select_image	Не имеет	Не имеет	Открывает диалоговое окно выбора изображения, отображает путь к нему и само изображение в интерфейсе

Продолжение таблицы 4.10

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
select_model	Не имеет	Не имеет	Открывает диалоговое окно выбора файла настроек модели и отображает путь к нему
analyze_image	Не имеет	Не имеет	Анализирует загруженное изображение при помощи нейронной сети и отображает результат распознавания
save_result	Не имеет	Не имеет	Открывает диалоговое окно выбора папки сохранения результата анализа изображения и сохраняет результат

#### 4.1.7 Модуль train\_ui.py

Модуль содержит графический интерфейс для настройки параметров и запуска процесса обучения модели нейронной сети.

Классы: TrainingThread, TrainingWidget.

Описание класса TrainingThread. Данный класс выполняет процесс обучения нейронной сети в отдельном потоке для избежания блокировки и зависания графического интерфейса. Базовый класс – QThread, стандартный класс библиотеки PyQt5. Интерфейсы – сигналы для передачи прогресса обучения и обработки ошибок, функция, управляющая процессом обучения. Константы отсутствуют. Внутренние поля представлены в таблице 4.11.

Таблица 4.11 – Внутренние поля класса TrainingThread

Внутреннее поле	Тип	Описание
trainer	Trainer	экземпляр класса Trainer из train.py для обучения нейронной сети
error_signal	pyqtSignal[str]	сигнал для передачи сообщений об ошибках в процессе обучения

Методы класса представлены в таблице 4.12.

Таблица 4.12 – Методы класса TrainigThread

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	dataset_path – путь к датасету; model_path – путь к директории сохранения модели; batch_size – размер батча; epochs – количество эпох обучения	Не имеет	Инициализирует поток обучения нейронной сети с экземпляром класса Trainer
run	Не имеет	Не имеет	Выполняет обучение нейронной сети с обработкой ошибок

Описание класса TrainingWidget. Класс предоставляет графический интерфейс для выбора параметров обучения и отображения прогресса. Базовый

класс – QWidget, стандартный класс PyQt5. Интерфейсы – поля ввода расположений датасета и сохранения результата, кнопки выбора путей, запуска обучения, шкала прогресса завершения обучения, текстовое поле для отображения сведений об обучении. Константы отсутствуют. Внутренние поля представлены в таблице 4.13.

Таблица 4.13 – Внутренние поля класса TrainingWidget

Внутреннее поле	Тип	Описание
dataset_label	QLabel	надпись «Папка датасета:>”
dataset_path_field	QTextEdit	поле для отображения выбранной папки датасета
select_dataset_button	QPushButton	кнопка для выбора папки датасета
model_label	QLabel	надпись «Папка сохранения:>”
model_path_field	QTextEdit	поле для отображения выбранной папки сохранения
select_model_button	QPushButton	кнопка для выбора папки сохранения
batch_size_label	QLabel	надпись «Размер батча:>”
batch_size_combo	QComboBox	выпадающий список для выбора размера батча
epochs_label	QLabel	надпись ”Количество эпох:”

### Продолжение таблицы 4.13

Внутреннее поле	Тип	Описание
epochs_field	QLineEdit	поле для ввода количества эпох обучения
progress_label	QLabel	надпись "Прогресс эпохи:"
progress_bar	QProgressBar	шкала прогресса обучения нейронной сети
log_label	QLabel	надпись "Процесс выполнения:"
output_text	QTextEdit	поле для отображения сведений о процессе обучения
train_button	QPushButton	кнопка для запуска обучения
thread	TrainingThread	поток для процесса обучения

Методы класса представлены в таблице 4.14.

Таблица 4.14 – Методы класса TrainigWidget

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	Не имеет	Не имеет	Инициализирует графический интерфейс, включая макет и элементы для настройки обучения и отображения прогресса

Продолжение таблицы 4.14

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
select_dataset_folder	Не имеет	Не имеет	Открывает диалоговое окно для выбора папки, содержащей датасет
select_model_path	Не имеет	Не имеет	Открывает диалоговое окно для выбора папки сохранения весов обученной нейронной сети
run_training	Не имеет	Не имеет	Проверяет корректность параметров обучения, заданных пользователем, отображает ошибки при наличии, создает поток обучения, подключает сигналы для обновления графического интерфейса
on_epoch_start	epoch – номер текущей эпохи обучения; total_epochs – общее количество эпох	Не имеет	Обновляет отображаемый журнал обучения нейронной сети записью о начале эпохи и сбрасывает шкалу прогресса при начале новой эпохи обучения

Продолжение таблицы 4.14

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
on_epoch_complete	epoch – номер завершенной эпохи; avg_loss – среднее значение потери за эпоху обучения	Не имеет	Обновляет отображаемый журнал информацией о завершении эпохи и заполняет шкалу прогресса по окончании эпохи обучения
on_batch_progress	batch – номер текущего батча; total_batches – общее количество батчей; loss – значение потери для текущего батча	Не имеет	Обновляет шкалу прогресса в процессе обучения
append_output	text – текст, добавляемый в журнал обучения	Не имеет	Добавляет текст в область отображения журнала
show_error	error_message – отображаемое сообщение об ошибке	Не имеет	Отображает диалоговое окно ошибки

#### 4.1.8 Модуль test.ui.py

Модуль предоставляет графический интерфейс для тестирования модели нейронной сети.

Классы: TestingThread, TestingWidget.

Описание класса TestingThread. Класс выполняет оценку модели в отдельном потоке, чтобы избежать зависаний графического интерфейса. Базовый класс – QThread, стандартный класс PyQt5. Интерфейсы класса – сигна-

лы для обновления графического интерфейса. Константы отсутствуют. Внутренние поля представлены в таблице 4.15.

Таблица 4.15 – Внутренние поля класса TestingThread

Внутреннее поле	Тип	Описание
image_path	str	путь к тестовому изображению
model_path	str	путь к файлу настроек модели нейронной сети
output_signal	pyqtSignal[str]	сигнал для сообщений о результатах тестирования
results_signal	pyqtSignal[dict]	сигнал для передачи результатов оценки
error_signal	pyqtSignal[str]	сигнал для сообщений об ошибках тестирования

Методы класса представлены в таблице 4.16.

Таблица 4.16 – Методы класса TestingThread

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
__init__	image_path – путь к тестовому изображению; model_path – путь к файлу параметров нейронной сети	Не имеет	Инициализирует поток, передавая в него пути к тестовому изображению и папке модели

### Продолжение таблицы 4.16

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
run	Не имеет	Не имеет	Выполняет оценку нейронной сети, отправляя результаты или ошибки через сигналы

Описание класса TestingWidget. Класс содержит графический интерфейс для выбора тестового изображения и файла весов модели, запуска оценки и отображения полученных метрик точности нейронной сети, целевой и предсказанной масок. Базовый класс – QWidget, стандартный класс PyQt5. Интерфейсы класса – поля для отображения путей к тестовому изображению и файлу весов, кнопки для выбора этих файлов и запуска тестирования, области для отображения изображений и метрик. Константы отсутствуют. Внутренние поля представлены в таблице 4.17.

Таблица 4.17 – Внутренние поля класса TestingWidget

Внутреннее поле	Тип	Описание
image_path	str	путь к тестовому изображению
model_path	str	путь к тестируемым параметрам модели
path_label	QLabel	надпись "Изображение для проверки модели:"
image_path_field	QTextEdit	поле для отображения пути к изображению
select_image_button	QPushButton	кнопка выбора изображения
model_label	QLabel	надпись "Путь к параметрам нейросети:"

## Продолжение таблицы 4.17

Внутреннее поле	Тип	Описание
model_path_field	QTextEdit	поле для отображения пути к параметрам модели
select_model_button	QPushButton	кнопка выбора модели
output_text	QTextEdit	поле для вывода метрик точности
input_text_label	QLabel	надпись "Исходное изображение"
input_image_label	QLabel	поле отображения входного изображения
gt_text_label	QLabel	надпись "Ожидаемый результат"
gt_mask_label	QLabel	поле отображения эталонной маски
pred_text_label	QLabel	надпись "Результат работы модели"
pred_mask_label	QLabel	поле отображения предсказанной маски
test_button	QPushButton	кнопка запуска тестирования
thread	TestingThread	поток выполнения тестирования

Методы класса представлены в таблице 4.18.

Таблица 4.18 – Методы класса TestingWidget

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
<code>__init__</code>	Не имеет	Не имеет	Инициализирует графический интерфейс, включая макет и элементы для тестирования и отображения результатов
<code>select_image</code>	Не имеет	Не имеет	Открывает диалоговое окно для выбора тестового изображения и добавляет путь в специальное поле
<code>select_model</code>	Не имеет	Не имеет	Открывает диалоговое окно для выбора файла весов нейронной сети и добавляет путь в специальное поле
<code>run_testing</code>	Не имеет	Не имеет	Проверяет входные данные, запускает поток тестирования и подключает сигналы для отображения результатов и ошибок
<code>show_results</code>	<code>results</code> – результаты тестирования нейронной сети	Не имеет	Отображает исходное изображения и результаты тестирования в графическом интерфейсе

Продолжение таблицы 4.18

Название метода	Параметры метода	Возвращаемое значение	Назначение метода
append_output	text – текст, отображаемый в области результатов тестирования	Не имеет	Добавляет текст в область отображения результатов тестирования
show_error	error_message – отображаемое сообщение об ошибке	Не имеет	Отображает диалоговое окно ошибки
numpy_to_quimage	np_array – массив, представляющий изображение; is_grayscale – флаг, определяющий, является ли изображение полутоновым	Преобразованное изображение	Преобразует маски результатов из массивов в изображения

## 4.2 Модульное тестирование разработанной программной системы

Модульный тест[19] для класса UNet из модуля model.py представлен в таблице 4.19.

Таблица 4.19 – Модульное тестирование класса UNet

Описание теста	Входные данные	Ожидаемый результат
Проверка инициализации модели	UNet(in_channels=1, out_channels=1)	Экземпляр класса UNet
Проверка прямого прохода	input_tensor (1, 1, 320, 624)	Тензор размера (1, 1, 320, 624)

## Продолжение таблицы 4.19

Описание теста	Входные данные	Ожидаемый результат
Проверка диапазона значений выхода модели	Тензор, полученный в предыдущем тесте	Все значения в диапазоне $[0, 1]$

Модульный тест для вычисления метрик модуля test.py представлен на рисунке 4.20.

Таблица 4.20 – Модульное тестирование модуля test.py

Описание теста	Входные данные	Ожидаемый результат
Проверка расчёта Dice коэффициента	$\text{pred} = [1, 1, 0, 0], \text{target} = [1, 0, 1, 0]$	$Dice \in [0, 1]$
Проверка расчёта IoU	$\text{pred} = [1, 1, 0, 0], \text{target} = [1, 0, 1, 0]$	$IoU \in [0, 1]$

Модульный тест для класса analyze\_return из модуля detect.py представлен на рисунке 4.21.

Таблица 4.21 – Модульное тестирования класса analyze\_return

Описание теста	Входные данные	Ожидаемый результат
Проверка возврата изображения после анализа	<code>self.img_path</code> – путь к сгенерированному текстовому изображению; <code>mock_load_model</code> – имитация параметров модели нейросети	Изображение в формате np.ndarray
Проверка размерности выходного изображения	<code>result</code> – изображение в формате np.ndarray из прошлого теста	<code>result.shape[2] == 3</code> – трехканальное BGR изображение

### 4.3 Системное тестирование разработанной программной системы

Для проведения системного тестирования был использован файл весов, полученный после обучения нейронной сети на датасете, состоящем из 777 изображений. Обучение проводилось на протяжении после 25 эпох.

На рисунке 4.1 представлено окно режима работы «Анализ изображения».




Рисунок 4.1 – Окно программы в режиме «Анализ изображения»

На рисунке 4.2 представлено диалоговое окно выбора анализируемого изображения.




Рисунок 4.2 – Диалоговое окно выбора анализируемого изображения

На рисунке 4.3 представлено диалоговое окно выбора файла весов модели нейронной сети для анализа.




Рисунок 4.3 – Диалоговое окно выбора файла весов

На рисунке 4.4 представлено отображение результата распознавания нефтяных пятен на поверхности водоемов.




Рисунок 4.4 – Результат распознавания нефтяных пятен

На рисунках 4.5 и 4.6 показано сохранение полученного нейросетью результата.




Рисунок 4.5 – Диалоговое окно выбора расположения сохранения




Рисунок 4.6 – Сохраненный результат

На рисунке 4.7 представлено окно режима работы «Обучение».




Рисунок 4.7 – Окно режима «Обучение»

На рисунке 4.8 представлено диалоговое окно выбора датасета.




Рисунок 4.8 – Диалоговое окно выбора датасета

На рисунке 4.9 представлено диалоговое окно выбора расположения сохранения весов.




Рисунок 4.9 – Диалоговое окно выбора расположения сохранения весов

На рисунках 4.10, 4.11 и 4.12 отображены процесс обучения, интерфейс программы после завершения обучения и полученный файл весов модели нейронной сети.




Рисунок 4.10 – Процесс обучения нейронной сети




Рисунок 4.11 – Интерфейс программы после завершения обучения




Рисунок 4.12 – Файл весов модели

На рисунке 4.13 изображено окно программы в режиме «Тестирование».




Рисунок 4.13 – Окно режима «Тестирование»

На рисунке 4.14 изображено диалоговое окно выбора тестового изображения.




Рисунок 4.14 – Диалоговое окно выбора тестового изображения

На рисунке 4.15 изображено диалоговое окно выбора тестируемых весов.




Рисунок 4.15 – Диалоговое окно выбора тестируемой модели

На рисунке 4.16 отображены результаты тестирования выбранных весов модели нейронной сети.




Рисунок 4.16 – Результаты тестирования

## **4.4 Сборка программной системы**

Программные компоненты представляют собой файлы исходных кодов программной системы.

Для сборки и компиляции программной системы использовалась библиотека Pyinstaller[20], позволяющая упаковать все необходимые файлы в один исполняемый файл формата .exe. Данный файл может быть запущен без предварительной установки.

Интерпретация исходных кодов на языке Python выполняется встроенным в исполняемый файл интерпретатором языка и не требует отдельной установки интерпретатора и библиотек на целевую систему.

Все программные компоненты собраны в один исполняемый файл, готовый к запуску в среде Windows.

## ЗАКЛЮЧЕНИЕ

Развитие нейронных сетей и методов машинного обучения открыло широкие возможности для автоматизации задач анализа изображений. Современные технологии позволяют обрабатывать большие объемы визуальных данных и своевременно выявлять потенциальные угрозы окружающей среде.

В условиях роста количества загрязнений водоемов, вызванных разливами нефти, применение интеллектуальных систем является эффективным инструментом мониторинга. Их использование позволяет значительно облегчить процесс обнаружения и снизить его стоимость, увеличивая при этом скорость применения.

Для решения задачи распознавания пятен нефтяных разливов была разработана интеллектуальная система на основе сверточной нейронной сети архитектуры U-Net. Система реализована в виде настольного приложения с графическим интерфейсом.

Основные результаты работы:

1. Проведен анализ предметной области. Проведено исследование причин возникновения разливов и нейронных сетей, являющихся наиболее эффективным методом автоматического распознавания.
2. Разработана концептуальная модель интеллектуальной системы, определены основные требования к системе и аппаратному обеспечению.
3. Осуществлено проектирование интеллектуальной системы. Разработана архитектура настольного приложения и нейронной сети. Разработан пользовательский интерфейс приложения.
4. Реализована интеллектуальная система, проведено модульное и системное тестирование разработанной нейронной сети и настольного приложения.

Все требования, объявленные в техническом задании, были полностью реализованы. Все задачи, поставленные в начале разработки проекта, были решены.

Готовый рабочий проект представлен в виде настольного приложения с графическим интерфейсом.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Алексеев Д. В. Сравнительный анализ баз данных по разливам нефти и нефтепродуктов с морских судов / Д. В. Алексеев, А. А. Лентарёв // Вестник Государственного университета морского и речного флота имени адмирала С. О. Макарова. — 2022. — Т. 14. — № 6. — С. 891–904. DOI: 10.21821/2309-5180-2022-14-6-891-904. — Текст: непосредственный.
2. Владимиров В. А. Разливы нефти: причины, масштабы, последствия // Стратегия гражданской защиты: проблемы и исследования. — 2014. — № 1. — URL: <https://cyberleninka.ru/article/n/razlivy-nefti-prichiny-masshtaby-posledstviya> (дата обращения: 10.05.2025). — Текст : непосредственный.
3. Клименко С. К., Иванов А. Ю., Терелева Н. В. Пленочные загрязнения Керченского пролива по данным пятилетнего радиолокационного мониторинга: современное состояние и основные источники // Исследование Земли из космоса. —2022. — № 3. — С. 37–54. — DOI: 10.31857/S0205961422030071. — Текст : непосредственный.
4. Горбачевская Е. Н., Краснов С. С. История развития нейронных сетей // Вестник ВУИТ. — 2015. — № 1 (23). — URL: <https://cyberleninka.ru/article/n/istoriya-razvitiya-nevronnyh-setey> (дата обращения: 11.05.2025). — Текст : непосредственный.
5. Митина О. А., Ломовцев П. П. Перцепtron в задачах бинарной классификации // НАУ. — 2021. — № 66-1. — URL: <https://cyberleninka.ru/article/n/pertseptron-v-zadachah-binarnoy-klassifikatsii> (дата обращения: 11.05.2025). — Текст : непосредственный.
6. Хайкин С. Нейронные сети: полный курс / Саймон Хайкин; пер. с англ. Н. Н. Куссуль. — 2-е изд., испр. — М.: Вильямс, 2018. — 1103 с. — ISBN 978-5-907144-22-4. — Текст: непосредственный.
7. Ростовцев В. С. Искусственные нейронные сети: учебник. — 5-е изд., стер. — СПб.: Лань, 2025. — 216 с. — ISBN 978-5-507-50568-5. — Текст: непосредственный.

8. Бычков А. Г., Киселёва Т. В., Маслова Е. В. Использование сверточных нейросетей для классификации изображений // Вестник Сибирского государственного индустриального университета. — 2022. — № 1. — С. 15–19. — Текст: непосредственный.
9. Годунов А. И., Баланян С. Т., Егоров П. С. Сегментация изображений и распознавание объектов на основе технологии сверточных нейронных сетей // Надежность и качество сложных систем. — 2021. — № 3. — С. 71–73. — Текст: непосредственный.
10. Фаулер М. UML. Основы. — 3-е изд. — СПб.: Символ-Плюс, 2015. — 192 с. — ISBN 978-5-93286-060-1. — Текст: непосредственный.
11. Лутц М. Изучаем Python. Том 1: учебное пособие / М. Лутц. — 5-е изд. — М.: Вильямс, 2020. — 832 с. — ISBN 978-5-907144-52-1. — Текст: непосредственный.
12. Шолле Ф. Глубокое обучение на Python / пер. с англ. — М.: ДМК Пресс, 2018. — 384 с. — ISBN 978-5-4461-0770-4. — Текст: непосредственный.
13. Лутц М. Изучаем Python. Том 2 / М. Лутц. — 5-е изд. — М.: Вильямс, 2020. — 720 с. — ISBN 978-5-907144-53-8. — Текст: непосредственный.
14. Пойнтер Я. Программируем с PyTorch: создание приложений глубокого обучения. — СПб.: Питер, 2020. — 256 с. — ISBN 978-5-4461-1677-5. — Текст: непосредственный.
15. Бендер Д. Python для анализа данных. — М.: ДМК Пресс, 2015. — 482 с. — ISBN 978-5-97060-315-4. — Текст: непосредственный.
16. Халяпин Д. Б. UML. Проектирование систем реального времени, параллельных и распределенных приложений / Д. Б. Халяпин. — Москва: Озон, 2023. — 352 с. — ISBN 978-5-6048804-3-2. — Текст: непосредственный.
17. Сорокин А. Б., Железняк Л. М., Зикеева Е. А. Сверточные нейронные сети: примеры реализаций: учебное пособие. — М.: МИРЭА, 2020. — 1 электрон. опт. диск (CD-ROM). — Текст: непосредственный.

18. Мюллер-Брокманн Й. Модульные системы в графическом дизайне.  
— М.: Студия Артемия Лебедева, 2018. — 176 с. — ISBN 978-5-98062-140-7.  
— Текст: непосредственный.
19. Хиллард Д. Публикация пакетов Python. Тестирование, распространение и автоматизация проектов. — М.: Бомбара, 2024. — 288с. — ISBN 978-5-04-189146-6. — Текст: непосредственный.
20. Васильев А. Н. Программирование на Python в примерах и задачах.  
— М.: Бомбара, 2021. — 384 с. — ISBN 978-5-04-103199-2. — Текст: непосредственный.

## **ПРИЛОЖЕНИЕ А**

### **Представление графического материала**

Графический материал, выполненный на отдельных листах, изображен на рисунках А.1–А.13.

# Сведения о ВКРБ

Минобрнауки России  
Юго-Западный государственный университет

Кафедра программной инженерии

## ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА ПО ПРОГРАММЕ БАКАЛАВРИАТА

∞

«Интеллектуальная система мониторинга и распознавания  
загрязнений водоемов»

Руководитель ВКРБ  
д.т.н., профессор  
Томакова Римма Александровна

Автор ВКРБ  
студент группы ПО-11б  
Конев Андрей Вячеславович

Сведения о ВКРБ			BKRБ 2106146.09.03.04.25.014
Фамилия И. О.	Номер	Код	Анн. Номер
Андрей Конев	А.В.		
Родился в г. Самара	1994.04.10		
Населенный пункт:	Чкалов А.А.		
			Анн. 1   Анн. 13
			Выпускная квалификационная работа Бакалавра
			ЮЗГУ ПО-11б

Рисунок А.1 – Сведения о ВКРБ

БДРБ 2106146.09.03.04.25.014	2																					
<h2>Актуальность проблемы</h2>																						
<p>Вода является одним из важнейших природных ресурсов, как для поддержания жизнедеятельности биологических систем, так и для обеспечения разнообразных промышленно-технологических процессов. В настоящее время водные ресурсы активно используются в различных ключевых отраслях промышленности и жизнедеятельности человека.</p>																						
<p>Загрязнение водоемов негативно сказывается на экологии, здоровье населения, препятствует развитию экономики, поэтому обеспечение экологической безопасности водоемов является одной из наиболее важных задач экологии. В настоящее время особую актуальность приобретает проблема нефтяных разливов.</p>																						
<table border="1"><tr><td colspan="2"></td><td>ВКРБ 2106146.09.03.04.25.014</td></tr><tr><td>Фамилия И. О.</td><td>Имя И.</td><td>Фамилия И. О.</td></tr><tr><td>Левин И. А.</td><td>Левин И.</td><td>Актуальность проблемы</td></tr><tr><td>Родина И. А.</td><td>Родина И.</td><td>Лист 2   Академия</td></tr><tr><td>Норникель</td><td>Чапкин А. А.</td><td>Выпускная квалификационная</td></tr><tr><td></td><td></td><td>работа Бакалавра</td></tr><tr><td></td><td></td><td>ЮЭГУ ПО-116</td></tr></table>				ВКРБ 2106146.09.03.04.25.014	Фамилия И. О.	Имя И.	Фамилия И. О.	Левин И. А.	Левин И.	Актуальность проблемы	Родина И. А.	Родина И.	Лист 2   Академия	Норникель	Чапкин А. А.	Выпускная квалификационная			работа Бакалавра			ЮЭГУ ПО-116
		ВКРБ 2106146.09.03.04.25.014																				
Фамилия И. О.	Имя И.	Фамилия И. О.																				
Левин И. А.	Левин И.	Актуальность проблемы																				
Родина И. А.	Родина И.	Лист 2   Академия																				
Норникель	Чапкин А. А.	Выпускная квалификационная																				
		работа Бакалавра																				
		ЮЭГУ ПО-116																				

Рисунок А.2 – Актуальность проблемы

БКРБ 2106146.09.03.04.25.014	3																												
<h2>Цель и задачи</h2>																													
<p>Цель данной выпускной квалификационной работы – разработка интеллектуальной системы для распознавания характерных пятен нефтяных разливов на поверхности водоемов.</p>																													
<p>Для достижения поставленной цели необходимо решить следующие задачи:</p>																													
<ol style="list-style-type: none"><li>1. Провести анализ предметной области.</li><li>2. Сформировать датасет обучающих изображений поверхности воды.</li><li>3. Разработать архитектуру нейронной сети.</li><li>4. Обучить нейронную сеть.</li><li>5. Провести оценку достоверности полученных результатов.</li><li>6. Спроектировать настольное приложение для анализа изображений.</li><li>7. Реализовать приложение, используя графический интерфейс.</li></ol>																													
<table border="1"><tr><td colspan="2">ВКРБ 2106146.09.03.04.25.014</td></tr><tr><td>Фамилия И. О.</td><td>Имя И.</td><td>Фамилия И. О.</td><td>Имя И.</td></tr><tr><td>Альберт Григорьевич</td><td>Григорьев А. Г.</td><td>Фамилия И. О.</td><td>Имя И.</td></tr><tr><td>Родился в г. Новосибирск</td><td>1990 г.</td><td>Родился в г. Новосибирск</td><td>1990 г.</td></tr><tr><td>Новосибирск</td><td>Членова А.А.</td><td>Новосибирск</td><td>Членова А.А.</td></tr><tr><td></td><td></td><td></td><td></td></tr><tr><td colspan="2">Цель и задачи</td><td>Лист 3   Альберт Григорьевич</td></tr><tr><td colspan="2">Выпускная квалификационная работа Бакалавра</td><td>ЮЭГУ ПО-116</td></tr></table>		ВКРБ 2106146.09.03.04.25.014		Фамилия И. О.	Имя И.	Фамилия И. О.	Имя И.	Альберт Григорьевич	Григорьев А. Г.	Фамилия И. О.	Имя И.	Родился в г. Новосибирск	1990 г.	Родился в г. Новосибирск	1990 г.	Новосибирск	Членова А.А.	Новосибирск	Членова А.А.					Цель и задачи		Лист 3   Альберт Григорьевич	Выпускная квалификационная работа Бакалавра		ЮЭГУ ПО-116
ВКРБ 2106146.09.03.04.25.014																													
Фамилия И. О.	Имя И.	Фамилия И. О.	Имя И.																										
Альберт Григорьевич	Григорьев А. Г.	Фамилия И. О.	Имя И.																										
Родился в г. Новосибирск	1990 г.	Родился в г. Новосибирск	1990 г.																										
Новосибирск	Членова А.А.	Новосибирск	Членова А.А.																										
Цель и задачи		Лист 3   Альберт Григорьевич																											
Выпускная квалификационная работа Бакалавра		ЮЭГУ ПО-116																											

Рисунок А.3 – Цель и задачи работы




Рисунок А.4 – Диаграмма прецедентов



Рисунок А.5 – Архитектура интеллектуальной системы

## Архитектура нейронной сети

Для распознавания нефтяных пятен на поверхности водоемов была реализована нейронная сеть типа Unet, архитектура которой содержит 13 слоев, из которых 11 – сверточные и 2 – транспонированные. В нейронной сети в качестве функции активации ReLU, а на выходе – сигмоидная функция.



ВКРБ 2106146.09.03.04.25.014		Лист	Номер
Фамилия И. О.	Инициалы И.О.		
Алехин Юрий АВ		Архитектура нейронной сети	
Родионова Екатерина РА			
Нургалиев Чаныза АА			
		Выпускная квалификационная работа бакалавра	
			ЮЭГУ ПО-116

Рисунок А.6 – Архитектура нейронной сети

## Обучение нейронной сети

Для обучения нейронной сети необходимо использовать полутоноевые изображения формата JPEG размера 1248x640 пикселей. Для обучения модели, использованной для тестирования интеллектуальной системы, использовалось 777 изображений с автоматическим разделением на обучающую (80%) и контрольную (20%) выборки.



ВКРБ 2106146.09.03.04.25.014		
Фамилия И. О.	Имя	Отчество
Андрейкович А.	Юрий	Аркадьевич
Родительство:	Отец	Родители
Неродительство:	Члены семьи	Алена

Обучение нейронной сети


Алена Юрий Аркадьевич

Выпускная квалификационная работа Бакалавра

ЮЭГУ ПО-118

Рисунок А.7 – Обучение нейронной сети

## Окно анализа изображения



ВКРБ 2106146.09.03.04.25.014	
Фамилия И. О.	Имячество
Андрей Евгеньевич	Конев А.В.
Родился в:	1993 г.
Наркологом:	Чижкова А.А.
Окно анализа изображения	
Адрес:	г. Краснодар
Выпускная квалификационная работа Бакалавра	
ЮЭГУ ПО-116	

Рисунок А.8 – Окно анализа изображения





Рисунок А.9 – Окно обучения нейронной сети

## Окно тестирования нейронной сети



ВКРБ 2106146.09.03.04.25.014		
Фамилия И. О.	Номер телефона	Англ.язык
Андрейков А.В.		Интерфейс тестирования
Родионов А.С.		нейронной сети
Нурисламов А.А.		Англ.язык   Академ.13
		Выпускная квалификационная
		работа Бакалавра
		ЮЭГУ ПО-116

Рисунок А.10 – Окно тестирования нейронной сети





Рисунок А.11 – Тестирование обученной нейронной сети

## Тестирование обученной нейронной сети

Результат тестирования нейронной сети на изображении, содержащем другие загрязнения водоемов.



		БКРБ 2106146.09.03.04.25.014		
Фамилия И. О.	Номер зем.	Лог.	Место	Номер
Андрейков А.В.				
Родионов А.С.	Родионов А.С.			
Нургалиев А.А.	Чимеков А.А.			

Тестирование обученной  
нейронной сети

Лог. 12	Лог. 13
Выпускная квалификационная работа Бакалавра	
ЮЭГУ ПО-116	

Рисунок А.12 – Тестирование обученной нейронной сети

## Заключение

Основные результаты работы:

1. Проведен анализ предметной области. Проведено исследование причин возникновения разливов и нейронных сетей, являющихся наиболее эффективным методом автоматического распознавания.
2. Разработана концептуальная модель интеллектуальной системы, определены основные требования к системе и аппаратному обеспечению.
3. Осуществлено проектирование интеллектуальной системы. Разработана архитектура настольного приложения и нейронной сети. Разработан пользовательский интерфейс приложения.
4. Реализована интеллектуальная система, проведено модульное и системное тестирование разработанной нейронной сети и настольного приложения.

Все задачи, поставленные в начале разработки проекта, были решены.

		ВКРБ 2106146.09.03.04.25.014		
		Атт.	Метка	Индекс
Фамилия И. О.	Имя И.	Печать	Семья	
Андрей Иванович	Конев А.В.			
Руководитель	Конев А.В.			
Научный консультант	Чичканов А.А.			

Рисунок А.13 – Заключение

## ПРИЛОЖЕНИЕ Б

### Фрагменты исходного кода программы

#### model.py

```
1 import torch
2 import torch.nn as nn
3
4 class UNet(nn.Module):
5     def __init__(self, in_channels=1, out_channels=1):
6         super(UNet, self).__init__()
7
8         def conv_block(in_c, out_c):
9             return nn.Sequential(
10                 nn.Conv2d(in_c, out_c, 3, padding=1),
11                 nn.ReLU(inplace=True),
12                 nn.Conv2d(out_c, out_c, 3, padding=1),
13                 nn.ReLU(inplace=True)
14             )
15
16         self.enc1 = conv_block(in_channels, 64)
17         self.enc2 = conv_block(64, 128)
18         self.pool = nn.MaxPool2d(2, 2)
19
20         self.bottleneck = conv_block(128, 256)
21
22         self.upconv2 = nn.ConvTranspose2d(256, 128, 2, 2)
23         self.dec2 = conv_block(256, 128)
24         self.upconv1 = nn.ConvTranspose2d(128, 64, 2, 2)
25         self.dec1 = conv_block(128, 64)
26
27         self.final_conv = nn.Conv2d(64, out_channels, 1)
28
29     def forward(self, x):
30         e1 = self.enc1(x)
31         e2 = self.enc2(self.pool(e1))
32         b = self.bottleneck(self.pool(e2))
33         d2 = self.upconv2(b)
34         d2 = torch.cat([d2, e2], dim=1)
35         d2 = self.dec2(d2)
36         d1 = self.upconv1(d2)
37         d1 = torch.cat([d1, e1], dim=1)
38         d1 = self.dec1(d1)
39         return torch.sigmoid(self.final_conv(d1))
```

#### train.py

```
1 import torch
2 from torch.utils.data import Dataset, DataLoader
3 import os
4 import numpy as np
5 from model import UNet
6 import argparse
7 from PyQt5.QtCore import QObject, pyqtSignal
```

```

8 from PIL import Image
9 from test import dice_coefficient, iou_score
10
11 class dataset(Dataset):
12     def __init__(self, image_dir, threshold=0.5, images=None):
13         self.image_dir = image_dir
14         self.threshold = threshold
15         if images is not None:
16             self.images = images
17         else:
18             self.images = [
19                 img for img in os.listdir(image_dir)
20                 if img.lower().endswith('.jpg', '.jpeg'))
21             ]
22
23     if not self.images:
24         raise ValueError(f"Папка {image_dir} не содержит изображений
25                     формата .jpg или .jpeg")
26
27     for img_name in self.images:
28         img_path = os.path.join(image_dir, img_name)
29         try:
30             with Image.open(img_path) as img:
31                 img.verify()
32         except Exception as e:
33             raise ValueError(f"Папка содержит поврежденные изображения")
34
35     def __len__(self):
36         return len(self.images)
37
38     def __getitem__(self, idx):
39         path = os.path.join(self.image_dir, self.images[idx])
40         img = Image.open(path).convert("L")
41         if img is None:
42             raise ValueError(f"Ошибка загрузки изображения: {path}")
43         img = img.resize((624, 320))
44         img = np.array(img).astype(np.float32) / 255.0
45         mask = (img < self.threshold).astype(np.float32)
46         img = np.expand_dims(img, axis=0)
47         mask = np.expand_dims(mask, axis=0)
48         return torch.tensor(img), torch.tensor(mask)
49
50     class Trainer(QObject):
51         epoch_start_signal = pyqtSignal(int, int)
52         epoch_complete_signal = pyqtSignal(int, float, float, float, float)
53         batch_progress_signal = pyqtSignal(int, int, float)
54         training_complete_signal = pyqtSignal(str)
55
56     def __init__(self, image_dir, save_path, batch_size=1, epochs=25, lr=1e
57     -4, threshold=0.3):
58         super().__init__()
59         self.image_dir = image_dir
60         self.save_path = save_path
61         self.batch_size = batch_size

```

```

60     self.epochs = epochs
61     self.lr = lr
62     self.threshold = threshold
63
64     def run(self):
65         self.training_complete_signal.emit(f"Загрузка датасета из: {self.
66             image_dir}")
67         all_images = [
68             img for img in os.listdir(self.image_dir)
69             if img.lower().endswith(('.jpg', '.jpeg'))
70         ]
71         np.random.seed(42)
72         all_images = np.array(all_images)
73         np.random.shuffle(all_images)
74         train_size = int(0.8 * len(all_images))
75         train_images = all_images[:train_size].tolist()
76         test_images = all_images[train_size: ].tolist()
77
78         train_dataset = dataset(self.image_dir, threshold=self.threshold,
79             images=train_images)
80         test_dataset = dataset(self.image_dir, threshold=self.threshold,
81             images=test_images)
82         train_dataloader = DataLoader(train_dataset, batch_size=self.
83             batch_size, shuffle=True)
84         test_dataloader = DataLoader(test_dataset, batch_size=self.batch_size
85             , shuffle=False)
86
87         device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
88         model = UNet().to(device)
89         criterion = torch.nn.BCELoss()
90         optimizer = torch.optim.Adam(model.parameters(), lr=self.lr)
91
92         for epoch in range(self.epochs):
93             total_loss = 0
94             self.epoch_start_signal.emit(epoch + 1, self.epochs)
95             model.train()
96             for i, (imgs, masks) in enumerate(train_dataloader, 1):
97                 imgs, masks = imgs.to(device), masks.to(device)
98                 preds = model(imgs)
99                 loss = criterion(preds, masks)
100                optimizer.zero_grad()
101                loss.backward()
102                optimizer.step()
103                total_loss += loss.item()
104                self.batch_progress_signal.emit(i, len(train_dataloader),
105                    loss.item())
106
107                avg_loss = total_loss / len(train_dataloader)
108
109                model.eval()
110                test_loss = 0
111                dice_scores = []
112                iou_scores = []
113                with torch.no_grad():

```

```

108     for imgs, masks in test_dataloader:
109         imgs, masks = imgs.to(device), masks.to(device)
110         preds = model(imgs)
111         loss = criterion(preds, masks)
112         test_loss += loss.item()
113         pred_mask = (preds > self.threshold).float()
114         dice_scores.append(dice_coefficient(pred_mask, masks).
115                             item())
116         iou_scores.append(iou_score(pred_mask, masks).item())
117
118         avg_test_loss = test_loss / len(test_dataloader) if len(
119             test_dataloader) > 0 else 0
120         avg_dice = np.mean(dice_scores) if dice_scores else 0
121         avg_iou = np.mean(iou_scores) if iou_scores else 0
122         self.epoch_complete_signal.emit(epoch + 1, avg_loss,
123                                         avg_test_loss, avg_dice, avg_iou)
124
125     torch.save(model.state_dict(), self.save_path)
126     self.training_complete_signal.emit(f"Модель сохранена в: {self.
127                                         save_path}")
128
129     def main():
130         parser = argparse.ArgumentParser(description="Обучение нейросети UNet")
131         parser.add_argument('--data', required=True, help="Путь к папке с
132                               изображениями")
133         parser.add_argument('--output', required=True, help="Путь для сохранения
134                               модели (model.pth)")
135         parser.add_argument('--batch-size', type=int, default=4, help="Размер
136                               батча (по умолчанию: 4)")
137         parser.add_argument('--epochs', type=int, default=25, help="Количество
138                               эпох (по умолчанию: 25)")
139         args = parser.parse_args()
140
141         trainer = Trainer(args.data, args.output, batch_size=args.batch_size,
142                           epochs=args.epochs)
143         trainer.run()
144
145     if __name__ == "__main__":
146         main()

```

### detect.py

```

1 import torch
2 import numpy as np
3 import cv2
4 from model import UNet
5 from PIL import Image
6 import io
7
8 DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
9
10 def load_model(model_path):
11     model = UNet()
12     model.load_state_dict(torch.load(model_path, map_location=DEVICE))
13     model.to(DEVICE)

```

```

14     model.eval()
15     return model
16
17 def analyze_return(image_path, model_path, threshold=0.5):
18     model = load_model(model_path)
19
20     with open(image_path, "rb") as f:
21         pil_img = Image.open(io.BytesIO(f.read()))
22         pil_img = pil_img.convert("RGB")
23         original_img = np.array(pil_img)[:, :, ::-1]
24         img_gray = np.array(pil_img.convert("L"))
25
26     orig_h, original_w = img_gray.shape
27     img_norm = img_gray.astype(np.float32) / 255.0
28     img_resized = cv2.resize(img_norm, (624, 320))
29     img_tensor = torch.tensor(np.expand_dims(img_resized, axis=(0, 1)), dtype
30                             =torch.float32).to(DEVICE)
31
32     with torch.no_grad():
33         pred = model(img_tensor)
34         if not torch.is_floating_point(pred):
35             raise ValueError("Model output is not a floating-point tensor")
36
37     mask = (pred.squeeze().cpu().numpy() > float(threshold)).astype(np.uint8)
38     mask = cv2.resize(mask, (original_w, orig_h))
39
40     contours, _ = cv2.findContours(mask, cv2.RETR_EXTERNAL, cv2.
41                                   CHAIN_APPROX_SIMPLE)
42     result = original_img.copy()
43     cv2.drawContours(result, contours, -1, (0, 0, 255), 2)
44
45     return result

```

Автор ВКР

А. В. Конев

(подпись, дата)

Руководитель ВКР

Р. А. Томакова

(подпись, дата)

Нормоконтроль

А. А. Чаплыгин

(подпись, дата)

**Место для диска**